

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

LAB 2

DECISION TREE MODELING AND IMPROVEMENT

Giảng viên: [GIẢNG VIÊN]
Sinh viên: [HỌ TÊN - MSSV]
[HỌ TÊN - MSSV]
[HỌ TÊN - MSSV]
[HỌ TÊN - MSSV]

Mục lục

Chương 1

Thực nghiệm và phân tích kết quả

1.1 Mục tiêu và thiết lập thực nghiệm

Ba bộ dữ liệu được dùng với ba vai trò khác nhau. Letter Recognition là bộ dữ liệu chính để đánh giá cây quyết định trên đặc trưng đã được trích xuất; Handwritten Digits kiểm tra khả năng áp dụng trên biểu diễn điểm ảnh; Covertypes kiểm tra khả năng mở rộng trên dữ liệu lớn. Cách tổ chức này giúp tránh kết luận dựa trên một dạng dữ liệu duy nhất.

Các notebook được chạy trên Kaggle với Linux, 4 CPU logic và không bật GPU. Mô hình `DecisionTreeClassifier` của scikit-learn huấn luyện và suy luận trên CPU. Mọi thí nghiệm dùng `random_state=42`, `test_size=0.20` và phân tầng theo nhãn. Không dùng tập test để chọn mô hình hoặc siêu tham số.

Bảng 1.1: Vai trò và quy mô các bộ dữ liệu

Bộ dữ liệu	Vai trò	Số mẫu	Đặc trưng	Số lớp
Letter Recognition	Bộ dữ liệu chính; đã loại trùng chính xác	18.668	16	26
Handwritten Digits	So sánh chéo trên điểm ảnh 8×8	1.797	64	10
Covertypes	Kiểm tra khả năng mở rộng	581.012	54	7

Letter Recognition được loại 1.332 dòng trùng chính xác trước khi chia dữ liệu, còn 18.668 mẫu. Các giá trị bị quy tắc IQR đánh dấu vẫn được giữ vì chúng nằm trong miền hợp lệ 0–15 của bộ dữ liệu. Decision Tree không yêu cầu chuẩn hóa thang đo hay one-hot encoding bổ sung cho ba bộ dữ liệu đã được chuẩn bị.

1.2 Chỉ số đánh giá

Kết quả được đánh giá bằng accuracy, error rate và macro-F1. Macro-F1 được ưu tiên khi phân bố lớp không cân bằng vì mỗi lớp đóng góp như nhau vào trung bình. Độ chênh giữa accuracy trên train và test được dùng như dấu hiệu overfitting. Độ sâu và số lá phản ánh độ phức tạp, trong khi thời gian nạp dữ liệu, huấn luyện, dự đoán và toàn pipeline phản ánh chi phí tính toán.

Với Covertypes, hai cấu hình được so sánh: cây baseline dùng Gini không giới hạn độ sâu và cây regularized với `max_depth=20`, `min_samples_leaf=5`. Việc chọn mô hình dựa trên macro-F1 trung bình của 5-fold cross-validation chỉ trên tập train. Kết quả CV được

trình bày dưới dạng trung bình $\pm$ độ lệch chuẩn.

1.3 Kết quả tổng hợp trên tập test


Bảng 1.2: Kết quả baseline trên tập test Kaggle

Bộ dữ liệu	Accuracy	Macro-F1	Error	Độ sâu	Số lá
Letter Recognition	0,8677	0,8677	0,1323	31	1.965
Handwritten Digits	0,8250	0,8230	0,1750	14	142
Covertypes	0,9389	0,9034	0,0611	41	23.956


Ba cây baseline đều đạt accuracy train bằng 1,0. Điều này cho thấy cây không cắt tỉa có khả năng ghi nhớ hoàn toàn tập huấn luyện. Khoảng cách train-test lần lượt là 0,1323 trên Letter Recognition, 0,1750 trên Digits và 0,0611 trên Covertypes. Vì vậy, kết quả test phải được đọc cùng độ phức tạp của cây thay vì chỉ nhìn vào accuracy train.

1.3.1 Letter Recognition

Baseline đạt accuracy 0,8677 và macro-F1 0,8677 trên 3.734 mẫu test. Hai giá trị gần nhau cho thấy chất lượng tương đối đồng đều giữa 26 lớp. Tuy nhiên, độ sâu 31 và 1.965 lá cùng accuracy train 1,0 cho thấy mô hình vẫn overfit; đây là cơ sở để thử pruning hoặc điều chỉnh `max_depth`, `min_samples_leaf` ở giai đoạn cải tiến.




Hình 1.1: Ma trận nhầm lẫn của Decision Tree baseline trên Letter Recognition.




Hình 1.2: Mức quan trọng của các đặc trưng trên Letter Recognition.

1.3.2 Handwritten Digits

Digits đạt accuracy 0,8250 và macro-F1 0,8230. Đây là kết quả thấp nhất trong ba bộ dữ liệu và có train-test gap lớn nhất. Một cây đơn lẻ phải chia không gian 64 chiều dựa trên từng điểm ảnh, nên nhạy với biến thiên nét viết và không khai thác được cấu trúc không gian tốt như các mô hình chuyên cho ảnh.




Hình 1.3: Ma trận nhầm lẫn của Decision Tree baseline trên Handwritten Digits.



Hình 1.4: Một số chữ số bị phân loại sai trên tập test.

1.3.3 Covertypes và đánh đổi hiệu năng - độ phức tạp

Covertypes có phân bố lớp lệch mạnh: lớp 1 và 2 chiếm đa số, còn lớp 4 có ít mẫu nhất. Vì vậy macro-F1 0,9034 được dùng cùng accuracy 0,9389 để tránh đánh giá quá lạc quan dựa trên hai lớp lớn. Mô hình baseline được chọn bởi 5-fold CV và đạt kết quả test tốt nhất, nhưng cây sâu 41 với 23.956 lá.





Hình 1.5: Phân bố bảy lớp của bộ dữ liệu Covertypes.

Bảng 1.3: So sánh hold-out giữa hai cấu hình trên Covertype


Mô hình	Train acc.	Test acc.	Macro-F1	Độ sâu	Số lá
Baseline	1,0000	0,9389	0,9034	41	23.956
Regularized	0,9268	0,8988	0,8432	20	9.679

Cấu hình regularized giảm 59,6% số lá và giảm train-test gap từ 0,0611 xuống 0,0279, nhưng accuracy test giảm 0,0400 và macro-F1 giảm 0,0602. Với hai cấu hình hiện tại, baseline vẫn là lựa chọn tốt hơn theo macro-F1; regularized minh họa rõ cái giá phải trả khi giảm mạnh độ phức tạp. Các thí nghiệm tiếp theo nên tìm vùng trung gian thay vì kết luận rằng mọi hình thức regularization đều làm mô hình kém hơn.

**Hình 1.6:** Đánh đổi giữa hiệu năng hold-out và độ phức tạp trên Covertype.



Hình 1.7: Ma trận nhầm lẫn của mô hình Covertypes được chọn bằng cross-validation.



Hình 1.8: Hai mươi đặc trưng quan trọng nhất của cây Covertypes baseline.

1.4 Độ ổn định qua cross-validation

Bảng 1.4: Kết quả 5-fold cross-validation trên tập train Covertypes

Mô hình	Accuracy	Macro-F1	Fit time (giây)
Baseline	0,9330 ± 0,0011	0,8923 ± 0,0011	8,6710 ± 0,0852
Regularized	0,8966 ± 0,0019	0,8388 ± 0,0028	7,4213 ± 0,1392

Độ lệch chuẩn nhỏ cho thấy kết quả ổn định giữa các fold. Baseline cao hơn regularized 0,0364 điểm accuracy và 0,0535 điểm macro-F1, trong khi thời gian fit trung bình chỉ tăng khoảng 1,25 giây mỗi fold. Do đó, tiêu chí macro-F1 chọn baseline là hợp lý trong phạm vi hai cấu hình đã thử.

1.5 Thời gian chạy trên Kaggle

Bảng 1.5: Thời gian của các pipeline Kaggle, đơn vị giây

Bộ dữ liệu	Nạp dữ liệu	Huấn luyện	Dự đoán	Toàn pipeline
Letter Recognition	0,0419	0,1264	0,0088	6,3916
Handwritten Digits	0,0424	0,0239	0,0030	5,1282
Covertypes	86,7835	10,5151	0,2834	162,0717

Hai bộ dữ liệu nhỏ hoàn tất trong vài giây. Với Covertypes, thời gian nạp dữ liệu chiếm 53,6% toàn pipeline và lớn hơn thời gian huấn luyện cây. Tổng thời gian còn bao gồm hai mô hình hold-out, 5-fold CV, sinh biểu đồ và đóng gói artifact. Điều này cho thấy nút thắt trong notebook hiện tại không chỉ nằm ở thuật toán Decision Tree mà còn ở I/O và quy trình đánh giá. GPU không giúp cải thiện bước huấn luyện vì estimator này chạy trên CPU.

1.6 Kết luận thực nghiệm

Kết quả từ ba bộ dữ liệu xác nhận Decision Tree là baseline nhanh, dễ diễn giải và có thể chạy trên dữ liệu hơn nửa triệu mẫu. Tuy nhiên, accuracy train bằng 1,0 trên cả ba baseline cho thấy nguy cơ overfitting rõ ràng. Covertypes đạt hiệu năng test cao nhất và ổn định qua 5-fold CV, nhưng cây rất lớn. Regularization mạnh làm cây gọn hơn đáng kể nhưng giảm chất lượng dự đoán. Vì vậy, bước cải tiến nên tìm mức cắt tỉa trung gian bằng cross-validation, đồng thời tiếp tục theo dõi macro-F1, train-test gap, số lá và thời gian thay vì tối ưu duy nhất accuracy.