

Decision Tree Modeling and Improvement

Từ cây cơ sở đến CCP và Hierarchical Shrinkage

Nhóm thực hiện

[HỌ TÊN – MSSV] [HỌ TÊN – MSSV]

[HỌ TÊN – MSSV] [HỌ TÊN – MSSV]

Introduction to Artificial Intelligence – Lab 2

Trường Đại học Khoa học Tự nhiên – ĐHQG TP.HCM

Cây dễ giải thích, nhưng cây sâu rất dễ overfit

Một cây không giới hạn có thể ghi nhớ tập train, tạo hàng chục nghìn lá và dự đoán quá tự tin ở các nhánh ít mẫu.

- 1 **RQ1 – Phù hợp dữ liệu:** Decision Tree hoạt động thế nào trên dữ liệu đa lớp, ảnh và dữ liệu bảng lớn?
- 2 **RQ2 – So sánh mô hình:** Khi nào cây đơn cạnh tranh được với RF, SVM và KNN?
- 3 **RQ3 – Cải tiến:** Regularization có giảm overfitting mà vẫn giữ hiệu năng và tính diễn giải không?

Nguồn: Breiman et al. (1984); mục tiêu nghiên cứu của nhóm.

Ba dataset tạo ra ba điều kiện kiểm thử khác nhau

Dataset	Mẫu	Features	Lớp	Vai trò trong nghiên cứu
Letter Recognition	18.668	16	26	Stress test đa lớp với đặc trưng hình học
Handwritten Digits	1.797	64	10	Stress test dữ liệu ảnh ít mẫu, nhiều chiều
Covertypes	581.012	54	7	Dataset chính: dữ liệu bảng lớn, mất cân bằng

Covertypes trả lời yêu cầu chính của đề; Letter và Digits kiểm tra xem kết luận có phụ thuộc một kiểu dữ liệu hay không.

Nguồn: UCI Letter Recognition; scikit-learn Digits; UCI Covertypes.

Một protocol chung giúp so sánh công bằng

Dữ liệu sạch → 80/20 stratified split → train → test cuối cùng

`random_state=42` | scaler chỉ fit trên train cho SVM/KNN |
CV chỉ dùng tập train

Chất lượng dự đoán

- Accuracy và Error rate
- Macro-F1 cho bài toán đa lớp
- Confusion matrix

Khả năng triển khai

- Train-test gap
- Fit/prediction time
- Độ sâu và số lá

lưu ý: Protocol chung của năm notebook, test set không tham gia chọn siêu tham số

CART xây cây bằng các phép chia giảm impurity

Chọn split làm giảm Gini nhiều nhất

$$Gini(S) = 1 - \sum_{k=1}^K p_k^2$$
$$\Delta G = Gini(S) - \frac{n_L}{n} Gini(L) - \frac{n_R}{n} Gini(R)$$

Nguồn: CART: Breiman et al. (1984).

Lập đệ quy $\rightarrow$ dừng $\rightarrow$ dự đoán lớp chiếm đa số tại lá


Điểm mạnh

- Quy tắc *if-then* đọc trực tiếp
- Không cần chuẩn hóa feature
- Fit nhanh trên dữ liệu bảng

Hạn chế

- Split theo từng trục
- Phương sai cao khi cây sâu

Baseline Covertypes dự đoán tốt nhưng tạo cây rất lớn



93,89%
Accuracy

6,11%
Error rate

90,34%
Macro-F1

Nguồn: Baseline CART trên Covertypes; hình chỉ hiển thị 3 tầng đầu.

Một luật top-level: nếu $\text{Elevation} \leq 3044,5$, mẫu đi sang nhánh mà lớp 2 chiếm ưu thế. Cây đầy đủ sâu **41 tầng** với **23.956** lá.


Không có mô hình tốt nhất trên mọi dataset

Dataset	Mô hình tốt nhất	Accuracy	Macro-F1	Ý nghĩa
Letter Recognition	Random Forest	95,13%	95,12%	Ensemble giảm phương sai của cây đơn
Handwritten Digits	SVM-RBF	97,22%	97,18%	Kernel phù hợp ranh giới ảnh nhiều chiều
Covertypes	Decision Tree	93,89%	90,34%	Cây khai thác hiệu quả dữ liệu bảng lớn

Lựa chọn mô hình phải dựa trên cấu trúc dữ liệu, không chỉ dựa trên danh tiếng thuật toán hoặc GPU.

Nguồn: Notebook so sánh 3 dataset × 4 model; cùng train/test split.

Generalization gap cho thấy Decision Tree cần regularization



Covertypes baseline đạt **100% train accuracy** nhưng chỉ **93,89% test accuracy: gap 6,11 điểm %**.

Nguồn: Train accuracy đo trên mẫu chuẩn đoán có định, test accuracy đo trên toàn bộ test set.

Ba phương pháp tác động vào hai phần khác nhau của cây

Phương pháp	Tác động	Cơ chế	Mục tiêu
Pre-pruning	Topology	Dừng sớm bằng depth/min samples	Tránh tạo nhánh quá chi tiết
Cost-Complexity Pruning	Topology	Cắt nhánh có đóng góp nhỏ bằng α	Giảm số lá sau khi fit
Hierarchical Shrinkage	Prediction	Kéo dự đoán nút con về nút cha bằng λ	Giảm độ tự tin ở nhánh ít mẫu

E4 = CCP + HS: CCP làm cây gọn trước; HS làm mượt dự đoán trên cây đã cắt tỉa.

Nguồn: CART pruning: Breiman et al. (1984); HS: Agarwal et al. (2022).

Hierarchical Shrinkage giảm ảnh hưởng của các lá ít mẫu

Cập nhật dự đoán theo từng cạnh cha $\rightarrow$ con

$$\hat{p}_{HS}(v) = \hat{p}_{HS}(pa(v)) + \frac{n_v}{n_v + \lambda} [\hat{p}(v) - \hat{p}(pa(v))]$$

- n_v lớn: giữ nhiều thông tin riêng của nút con.
- n_v nhỏ hoặc λ lớn: dự đoán được kéo mạnh hơn về nút cha.
- Split, depth và số lá **không đổi**; chỉ probability estimate thay đổi.

Nguồn: Aggarwal et al. (2022); Hierarchical Node-Based Shrinkage của 10/15

λ và ccp_alpha được chọn bằng 3-fold CV chỉ trên tập train.


HS đạt accuracy cao nhất, CCP + HS đạt macro-F1 tốt nhất

Cấu hình	Accuracy	Error	Macro-F1	Depth	Leaves
E0 Baseline	93,89%	6,11%	90,34%	41	23.956
E1 Pre-pruning	92,97%	7,03%	88,85%	40	16.637
E2 CCP	93,92%	6,08%	90,45%	39	16.361
E3 HS	93,97%	6,03%	90,48%	41	23.956
E4 CCP + HS	93,93%	6,07%	90,53%	39	16.361

Vì Covertypes mất cân bằng, nhóm chọn **E4**: macro-F1 cao nhất, gap thấp hơn và cây nhỏ hơn E3.

Nguồn: HS benchmark trên Covertypes; 3-fold CV chọn tham số trên train.

CCP + HS giảm 31,7% số lá và 17,6% gap



—31,7%

số lá: 23.956 → 16.361

—17,6%

train-test gap: 6,11 → 5,04
điểm %

+0,19 điểm %

macro-F1: 90,34% → 90,53%

Cải tiến chính nằm ở trade-off: cây gọn hơn và ít overfit hơn mà hiệu năng test không giảm.

Nguồn: So sánh E0 với E4 trên 116.203 mẫu test Covertype.

Cải tiến chỉ rõ rệt khi dữ liệu và cây đủ lớn

Dataset	Δ Accuracy	Δ Macro-F1	Δ Leaves	Kết luận E4 so với baseline
Letter Recognition	+0,11 điểm %	+0,11 điểm %	0%	HS cải thiện nhẹ nhưng chưa làm cây gọn
Handwritten Digits	-0,83 điểm %	-0,71 điểm %	-54,9%	Cắt mạnh gây mất hiệu năng trên dữ liệu nhỏ
Covertypes	+0,05 điểm %	+0,19 điểm %	-31,7%	Trade-off tốt nhất ở quy mô lớn

HS không phải “thuốc tăng accuracy” phổ quát; lợi ích phụ thuộc số mẫu, độ sâu cây và độ ổn định của ước lượng tại nút.

Nguồn: E0 và E4 trên ba dataset; cùng protocol và seed.

Kết quả mạnh, nhưng không nên diễn giải quá mức

Ba giới hạn cần nói rõ

- Kết quả chính dùng một split với `random_state=42`; chưa lặp nhiều seed hay kiểm định thống kê.
- Decision Tree/HS chạy scikit-learn trên CPU; RF/SVM/KNN chạy cuML trên Tesla T4. Runtime là chi phí pipeline, **không phải speedup CPU-GPU thuần túy**.
- RF trên Covertypes phụ thuộc backend và siêu tham số khảo sát; không thể kết luận Decision Tree luôn vượt Random Forest.

Nguồn: E

Kết luận: E4 cải thiện trade-off Covertypes; chưa đủ bằng chứng HS luôn tốt hơn.

Decision Tree phù hợp nhất với dữ liệu bảng lớn

RQ1 – Phù hợp dữ liệu: cây đơn mạnh nhất trên Covertypes, nhưng yếu hơn trên Letter và Digits.

RQ2 – So sánh mô hình: không có thuật toán thắng mọi dataset; cấu trúc dữ liệu quyết định lựa chọn.

RQ3 – Cải tiến: CCP + HS phù hợp nhất khi cây sâu, dữ liệu lớn và cần cân bằng hiệu năng với khả năng diễn giải.

Cây tốt hơn không chỉ chính xác hơn – mà còn đủ gọn, đủ ổn định và vẫn giải thích được.


Appendix: Kết quả đầy đủ của 3 dataset × 4 model

Dataset	Model	Accuracy	Macro-F1	Error	Tổng time (s)
Letter	Decision Tree	86,77%	86,77%	13,23%	0,084
	Random Forest	95,13%	95,12%	4,87%	3,097
	SVM-RBF	92,31%	92,32%	7,69%	3,707
	KNN	94,08%	94,08%	5,92%	0,005
Digits	Decision Tree	82,50%	82,30%	17,50%	0,021
	Random Forest	96,94%	96,89%	3,06%	0,628
	SVM-RBF	97,22%	97,18%	2,78%	0,718
	KNN	96,39%	96,34%	3,61%	0,003
Covertypes	Decision Tree	93,89%	90,34%	6,11%	7,409
	Random Forest	79,57%	65,86%	20,43%	2,995
	SVM-RBF	79,07%	63,78%	20,93%	125,547
	KNN	92,84%	87,32%	7,16%	5,756

Nguồn: gpu_three_dataset_four_model_comparison_summary.csv.

Runtime phản ánh backend và pipeline thực tế; không dùng để suy ra speedup phần cứng thuần túy.

Appendix: Confusion matrix cho thấy lỗi tập trung ở lớp thiểu số



Nguồn: Decision Tree baseline trên tập test Covertypes.

Appendix: Tham số cải tiến được chọn chỉ từ tập train

Dataset	Pre-pruning	CCP	HS
Letter	max_depth=16	$\alpha = 0$	$\lambda = 10$
Digits	max_depth=8 min_samples_leaf	$\alpha = 0,002196$	$\lambda = 10$
Covertypes	=5	$\alpha = 3,442 \times 10^{-6}$	$\lambda = 10$

3-fold cross-validation trên train chọn cấu hình; test set chỉ được mở để báo cáo cuối cùng.

Nguồn: HS CV selection; Covertypes scalability cross-validation.

5-fold CV độc lập cho baseline Covertypes: accuracy $0,9330 \pm 0,0011$; macro-F1 $0,8923 \pm 0,0011$.

Appendix: Hardware, tài liệu và đóng góp nhóm

Hardware/backend. Kaggle GPU x2; cuML ghi nhận Tesla T4 cho RF/SVM/KNN. Decision Tree và HS dùng scikit-learn trên CPU; notebook baseline ghi nhận P100 khả dụng nhưng compute device vẫn là CPU.

Tài liệu chính. Breiman et al. (1984), *Classification and Regression Trees*; Agarwal et al. (2022), *Hierarchical Shrinkage*; UCI Letter Recognition và Covertypes; scikit-learn Digits; RAPIDS cuML.

Đóng góp thành viên.

[HỌ TÊN – MSSV]	[Dữ liệu / baseline / kiểm thử]
[HỌ TÊN – MSSV]	[Benchmark model / Kaggle GPU]
[HỌ TÊN – MSSV]	[Hierarchical Shrinkage / phân tích]
[HỌ TÊN – MSSV]	[Report / slide / tổng hợp kết quả]

Nguồn: Metadata notebook; tài liệu tham khảo trong report.