

Decision Tree Modeling and Improvement

Lab 2 – Introduction to Artificial Intelligence

Nhóm thực hiện

ĐẠI HỌC QUỐC GIA TP.HCM
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

2026

Ba câu hỏi dẫn dắt toàn bộ thí nghiệm

Decision Tree hoạt động thế nào trên các kiểu dữ liệu khác nhau?

Mô hình nào cho chất lượng dự đoán tốt hơn?

Regularization có giảm overfitting mà vẫn giữ tính diễn giải không?

Thiết kế thực nghiệm thống nhất để so sánh công bằng

3 datasets 4 models 1 protocol

Letter Recognition ▪ Handwritten Digits ▪ Covertypes

Accuracy, macro-F1, train–test gap, thời gian và độ phức tạp cây


Random Forest dẫn đầu trên Letter Recognition



Nhận xét: Random Forest đạt khoảng 0.951 accuracy/macro-F1; Decision Tree chỉ khoảng 0.868 nhưng vẫn là mô hình dễ giải thích nhất.


Các tầng đầu của cây vẫn đọc được trực tiếp

Letter Recognition - first three levels of the baseline tree




Nhận xét: Một vài split đầu cho thấy logic phân loại rõ ràng, nhưng cây đầy đủ phát triển sâu và cần regularization để kiểm soát độ phức tạp.

Một nhóm nhỏ đặc trưng chi phối quyết định của cây




Nhận xét: Các đặc trưng như x-ege, y2bar và y-ege đóng góp lớn nhất; importance giảm nhanh ở phần còn lại.

Độ sâu khoảng 16 đã gần chạm trần hiệu năng




Nhận xét: Test score tăng mạnh đến vùng depth 12–16 rồi gần như bão hòa, trong khi train accuracy tiếp tục tiến tới 1.0.

Pruning quá mạnh làm cây mất nhanh khả năng dự đoán




Nhận xét: Hiệu năng ổn định khi ccp_alpha còn nhỏ; khi α tăng lớn, cả accuracy và macro-F1 cùng suy giảm rõ rệt.

SVM nhỉnh nhất trên Handwritten Digits




Nhận xét: SVM và Random Forest đều gần 0.97, trong khi Decision Tree dừng ở khoảng 0.825 vì dữ liệu pixel tạo nhiều ranh giới phức tạp.

Các lỗi Digits tập trung ở những nét viết tương tự




Nhận xét: Những cặp chữ số có hình dạng gần nhau dễ bị nhầm; pixel thô khiến một cây đơn khó khái quát mọi biến thể nét viết.

Decision Tree lại mạnh nhất trên Covertypes




Nhận xét: Trong cấu hình khảo sát, Decision Tree đạt khoảng 0.939 accuracy và 0.903 macro-F1, cao hơn ba mô hình benchmark còn lại.

Chi phí tính toán thay đổi mạnh theo mô hình và dataset



Nhận xét: Trục log cho thấy chênh lệch nhiều bậc độ lớn; Decision Tree giữ thời gian huấn luyện và dự đoán cạnh tranh khi dữ liệu tăng lớn.

Decision Tree có train-test gap lớn nhất




Nhận xét: Khoảng cách đặc biệt rõ trên Letter và Digits, xác nhận cây không cắt tĩa dễ overfit hơn các mô hình benchmark.

Regularization gần như không cải thiện Letter Recognition




Nhận xét: HS chỉ tạo thay đổi rất nhỏ; pre-pruning làm giảm điểm, còn CCP tốt nhất gần như tương đương baseline.

Baseline vẫn tốt nhất trên Handwritten Digits




Nhận xét: Các cấu hình regularization không vượt baseline, cho thấy giảm độ phức tạp chưa chắc giúp khi dữ liệu nhỏ và ranh giới lớp phức tạp.

Covertypes hưởng lợi rõ nhất từ regularization



Nhận xét: CCP và HS giữ macro-F1 quanh 0.905 trong khi kiểm soát cấu trúc cây tốt hơn; đây là dataset phù hợp nhất cho cải tiến.

CCP + HS tạo trade-off tốt nhất ở quy mô lớn



Nhận xét: Trên Covertypes, cấu hình kết hợp giảm khoảng 31.7% số lá và 17.6% train-test gap mà vẫn giữ macro-F1 gần mức cao nhất.

Kết luận: không có một mô hình tốt nhất cho mọi dữ liệu

Decision Tree nổi bật về tính diễn giải và hiệu quả trên Covertypes.

Random Forest / SVM dẫn đầu trên Letter và Digits.

Regularization hữu ích nhất khi cây đủ lớn và overfitting đủ rõ.