

Decision Tree Modeling and Improvement

Từ cây cơ sở đến CCP và Hierarchical Shrinkage

Nhóm thực hiện

[HỌ TÊN – MSSV] [HỌ TÊN – MSSV]

[HỌ TÊN – MSSV] [HỌ TÊN – MSSV]

Introduction to Artificial Intelligence – Lab 2

Trường Đại học Khoa học Tự nhiên – ĐHQG TP.HCM

Cây dễ giải thích nhưng có thể ghi nhớ tập train

1 | BỐI CẢNH VÀ ĐỘNG LỰC

Split tham lam + điều kiện dừng lỏng $\Rightarrow$ cây sâu, nhiều lá và high variance.

- Mỗi path là một luật *if-then* có thể truy vết.
- Khả năng diễn giải toàn cục giảm nhanh khi số lá tăng.
- Mục tiêu là giữ score, giảm gap và làm cây gọn hơn.

Covertypes hoàn thành core Lab; hai dataset còn lại kiểm tra độ bền

1 | BỐI CẢNH VÀ ĐỘNG LỰC

Core Lab – Covertypes

- Build và phân tích cây.
- Accuracy, Error rate, Macro-F1.
- Ba phương pháp cải tiến.

Extended study

- Letter và Digits: robustness.
- RF, SVM, KNN: benchmark.
- CV, runtime, complexity.

Trọng tâm xuyên suốt vẫn là **Decision Tree cơ sở** → **phân tích**
→ **cải tiến.**

CART bổ sung split nhị phân, Gini và pruning cho cây quyết định

2 | CÁC CÔNG TRÌNH LIÊN QUAN

Thuật toán	Công trình	Đóng góp
ID3	Quinlan (1986)	Information gain
C4.5	Quinlan (1993)	Feature liên tục, gain ratio
CART	Breiman et al. (1984)	Binary split, Gini, cost-complexity pruning
HS	Agarwal et al. (2022)	Làm mượt prediction theo hierarchy

Nghiên cứu dùng CART làm baseline và HS như prediction regularization.

CART chọn phép chia làm giảm Gini nhiều nhất

3 | KIẾN THỨC NỀN TẢNG

$$Gini(S) = 1 - \sum_{k=1}^K p_k^2$$

$$\Delta G(j, t) = Gini(S) - \frac{n_L}{n} Gini(S_L) - \frac{n_R}{n} Gini(S_R)$$

- $Gini = 0$ khi nút chỉ chứa một lớp.
- Chọn $(j^*, t^*) = \arg \max_{j, t} \Delta G(j, t)$.
- Lặp cùng phép chọn tham lam tại mỗi nút con.

Điều kiện dừng quyết định cây có phát triển quá sâu hay không

3 | KIẾN THỨC NỀN TẢNG

```
BuildTree(S):  
  if Stop(S): return Leaf( $\hat{p}(y | S)$ )  
   $(j^*, t^*) \leftarrow \arg \max_{j, t} \Delta G(j, t)$   
   $S_L, S_R \leftarrow \text{Split}(S, j^*, t^*)$   
  return Node(BuildTree( $S_L$ ), BuildTree( $S_R$ ))
```

Stop quá lỏng $\Rightarrow$ nhánh ít mẫu $\Rightarrow$ prediction cực đoan và phương sai cao.

Ba dataset tạo ra ba chế độ kiểm thử khác nhau

4 | PHƯƠNG PHÁP NGHIÊN CỨU

Dataset	Mẫu	Features	Vai trò
Letter Recognition	18,668	16	Robustness: 26 lớp, feature hình học
Handwritten Digits	1,797	64	Robustness: ảnh nhỏ, nhiều chiều
Covertypes	581,012	54	Primary: bảng lớn, 7 lớp mất cân bằng

Covertypes có đủ mẫu và complexity để quan sát tác động regularization.

Train-only validation giữ test set độc lập

4 | PHƯƠNG PHÁP NGHIÊN CỨU

Data $\longrightarrow$ 80/20 stratified split

Train $\longrightarrow$ 3-fold CV chọn tham số $\longrightarrow$ fit lại $\longrightarrow$ Test

- `random_state=42`; cùng test set cho mọi model.
- Scaler chỉ fit train và chỉ dùng cho SVM/KNN.
- Baseline Covertypes được kiểm tra thêm bằng 5-fold CV.

Baseline E0 là một CART chưa giới hạn độ sâu

4 | PHƯƠNG PHÁP NGHIÊN CỨU

Cấu hình E0

- `criterion=gini`
- `splitter=best`
- `max_depth=None`
- `min_samples_leaf=1`
- `ccp_alpha=0`


`random_state=42`; các tham số khác dùng mặc định scikit-learn.

Chỉ số báo cáo

- Accuracy và Error rate
- Macro-F1, confusion matrix
- Train-test gap
- Depth, number of leaves

Root split của cây Covertypes là $\text{Elevation} \leq 3044.5$

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ



Chỉ hiển thị các tầng đầu; toàn cây có **depth 41** và **23,956 leaves**.

Các path thật cho thấy cây giải thích cục bộ nhưng khó đọc toàn cục

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ

Rule	Kết quả	Điều kiện nổi bật trên path
R1	Lớp 2; $n = 264$	Elevation thấp, Wilderness 0, gần hydrology
R2	Lớp 5; $n = 71$	Elevation thấp, xa fire point và roadway > 621
R3	Lớp 1; $n = 298$	Elevation > 3360.5 , Wilderness 2, Soil 31 vắng

Ba luật đều là lá thuần trên train, nhưng toàn cây có gần **24 nghìn luật**.

Baseline dự đoán tốt nhưng đạt lỗi train bằng không

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ

93.89%

Test accuracy

6.11%

Error rate

90.34%


Macro-F1

Train accuracy = 100% $\Rightarrow$ train-test gap = 6.11 điểm phần trăm.

Zero train error + depth 41 + 23,956 leaves là bằng chứng nhất quán với high variance.

Lớp 4 và 5 có recall thấp hơn rõ rệt

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ



Recall theo lớp

- Lớp 1: 93.80%
- Lớp 2: 94.83%
- Lớp 4: 84.88%
- Lớp 5: 84.47%
- Lớp 6: 87.24%

Macro-F1 giúp lớp nhỏ không bị lớp 1–2 lấn át.

Ba phương pháp nhắm vào ba điểm yếu khác nhau của baseline

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ

Quan sát ở E0	Phương pháp	Vị trí tác động
Cây tiếp tục phát triển sâu	Pre-pruning	Điều kiện dừng
Nhiều subtree đóng góp nhỏ	CCP	Topology sau khi fit
Nút sâu dự đoán quá tự tin	HS	Xác suất tại nút

E1, E2, E3 là ba phương pháp; **E4 chỉ là combined extension.**

Pre-pruning giảm gap nhưng dừng cây quá sớm

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ

Covertypes E1

- `min_samples_leaf=5`
- Leaves: 23,956 $\rightarrow$ 16,637
- Gap: 6.11% $\rightarrow$ 4.10%

Đánh đổi

- Accuracy: 92.97%
- Error rate: 7.03%
- Macro-F1: 88.85%

Early stopping giảm variance nhưng đã loại cả cấu trúc hữu ích $\Rightarrow$ underfit.

CCP cắt 31.7% số lá mà giữ nguyên hiệu năng test

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ

$$T_{\alpha} = \arg \min_{T \subseteq T_0} [R(T) + \alpha |\mathcal{L}(T)|]$$

3.442×10^{-6}
 α chọn bởi CV

16,361
Leaves

90.45%
Macro-F1

Depth 41 $\rightarrow$ 39; error rate 6.11% $\rightarrow$ 6.08%.

HS tăng score bằng cách làm mượt prediction, không cắt cây

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ

$$\hat{p}_{HS}(v) = \hat{p}_{HS}(pa(v)) + \frac{n_v}{n_v + \lambda} [\hat{p}(v) - \hat{p}(pa(v))]$$

- CV chọn $\lambda = 10$; nút ít mẫu bị kéo mạnh hơn về nút cha.
- E3 đạt accuracy cao nhất: 93.97%; macro-F1 90.48%.
- Topology không đổi: depth 41 và 23,956 leaves.

E3 thắng accuracy; E4 thắng trade-off tổng thể


5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ

Cấu hình	Accuracy	Error	Macro-F1	Gap	Depth	Leaves
E0 Baseline	93.89%	6.11%	90.34%	6.11%	41	23,956
E1 Pre-pruning	92.97%	7.03%	88.85%	4.10%	40	16,637
E2 CCP	93.92%	6.08%	90.45%	5.07%	39	16,361
E3 HS	93.97%	6.03%	90.48%	5.70%	41	23,956
E4 CCP + HS	93.93%	6.07%	90.53%	5.04%	39	16,361

E4 thấp hơn E3 chỉ 0.04 điểm phần trăm accuracy nhưng nhỏ hơn 31.7% về số lá.

E4 cải thiện complexity và gap rõ hơn score

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ



—31.7%
number of leaves

—17.6%
train–test gap

+0.19 pp
Macro-F1

Cải tiến chính là performance–complexity trade-off, không phải accuracy đơn thuần.

Regularization chỉ có lợi rõ trên cây đủ lớn

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ

Dataset	Δ Macro-F1	Δ Leaves	E4 so với E0
Letter	+0.11 pp	0.0%	Hiệu ứng rất nhẹ; $\alpha = 0$
Digits	-0.71 pp	-54.9%	Cây nhỏ nhưng mất điểm
Covertypes	+0.19 pp	-31.7%	Trade-off tốt nhất

HS không phải “thuốc tăng điểm” phổ quát; tác động phụ thuộc data regime.

Không có mô hình tốt nhất trên mọi dataset

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ

Dataset	Mô hình tốt nhất	Accuracy	Macro-F1
Letter Recognition	Random Forest	95.13%	95.12%
Handwritten Digits	SVM-RBF	97.22%	97.18%
Covertypes	Decision Tree	93.89%	90.34%

Kết quả chỉ áp dụng cho implementation và hyperparameters đã thử; không suy rộng thứ hạng thuật toán.

CV và artifact tracking làm kết quả có thể tái lập

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ

Validation

- 3-fold CV chọn α, λ .
- Test không tham gia tuning.
- Covertypes E0 có 5-fold CV.

Covertypes 5-fold

- Accuracy: $93.30\% \pm 0.11$ pp
- Macro-F1: $89.23\% \pm 0.11$ pp
- Cùng split contract và seed.

JSON/CSV lưu metrics, parameters, hardware và đường dẫn artifact cho từng notebook.

Kết luận được giới hạn bởi seed, tuning và backend

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ

- ① **Một holdout chính:** cần lặp nhiều seed cho effect size nhỏ.
- ② **Tuning chưa exhaustive:** RF/SVM/KNN chưa được tối ưu toàn diện.
- ③ **CPU/GPU khác nhau:** runtime không phải speedup phần cứng thuần túy.
- ④ **Gain nhỏ:** chưa có kiểm định thống kê nhiều lần lấy mẫu.

Kết luận mạnh nhất: **E4 cải thiện trade-off trên Covertypes**,
không phải HS luôn tốt hơn.

Cây tốt hơn phải chính xác, gọn và tổng quát hóa tốt

6 | KẾT LUẬN

- **RQ1:** Decision Tree phù hợp nhất với dữ liệu bảng lớn Covertypes.
- **RQ2:** RF thắng Letter, SVM thắng Digits; không có universal winner.
- **RQ3:** CCP giảm topology, HS làm mượt prediction; E4 kết hợp hai cơ chế.

E4 giữ Macro-F1, giảm 31.7% số lá và giảm 17.6% gap trên Covertypes.

Appendix: Bảng đầy đủ 3 datasets × 4 models

Dataset	Model	Accuracy	Macro-F1	Error	Runtime (s)
Letter	Decision Tree	86.77%	86.77%	13.23%	0.084
	Random Forest	95.13%	95.12%	4.87%	3.097
	SVM-RBF	92.31%	92.32%	7.69%	3.707
	KNN	94.08%	94.08%	5.92%	0.005
Digits	Decision Tree	82.50%	82.30%	17.50%	0.021
	Random Forest	96.94%	96.89%	3.06%	0.628
	SVM-RBF	97.22%	97.18%	2.78%	0.718
	KNN	96.39%	96.34%	3.61%	0.003
Covertypes	Decision Tree	93.89%	90.34%	6.11%	7.409
	Random Forest	79.57%	65.86%	20.43%	2.995
	SVM-RBF	79.07%	63.78%	20.93%	125.547
	KNN	92.84%	87.32%	7.16%	5.756

Runtime phản ánh backend/pipeline thực tế, không phải speedup CPU-GPU có kiểm soát.

Appendix: Tham số cải tiến được chọn từ train

Dataset	Pre-pruning	CCP	HS
Letter	max_depth=16	$\alpha = 0$	$\lambda = 10$
Digits	max_depth=8	$\alpha = 0.002196$	$\lambda = 10$
Covertypes	min_samples _leaf=5	$\alpha = 3.442 \times 10^{-6}$	$\lambda = 10$

3-fold CV chỉ dùng train; test set chỉ dùng báo cáo cuối.

Digits E4 chọn $\lambda = 0$ sau CCP; Letter chọn $\alpha = 0$.

Appendix: Ba decision rules đầy đủ từ cây baseline

R1 → lớp 2 ($n = 264$, depth 6):

Elevation ≤ 3044.5 ; Elevation ≤ 2510.5 ; Hydrology > 15 ; Wilderness 0 = 1; Fire Points ≤ 5122 ; Hydrology ≤ 300.5 .

R2 → lớp 5 ($n = 71$, depth 6):


Elevation ≤ 3044.5 ; Elevation ≤ 2510.5 ; Hydrology > 15 ; Wilderness 0 = 1; Fire Points > 5122 ; Roadways > 621 .

R3 → lớp 1 ($n = 298$, depth 7):

Elevation > 3044.5 ; Elevation > 3322.5 ; Wilderness 2 = 1; Soil 31 = 0; Elevation > 3360.5 ; Fire Points ≤ 403 ; Roadways > 2934.5 .

Các lá thuần trên train không phải luật nhân quả hay bảo đảm 100% trên dữ liệu mới.

Appendix: Elevation chi phối feature importance



Appendix: Hardware và backend được công bố tách biệt

Thí nghiệm	Backend	Thiết bị ghi nhận
Decision Tree / HS	scikit-learn	CPU; P100 khả dụng nhưng không dùng compute
RF / SVM / KNN	RAPIDS cuML	Tesla T4 trong phiên Kaggle GPU x2

- GPU x2 là cấu hình môi trường, không khẳng định hai GPU chạy song song.
- Runtime không dùng để suy ra speedup CPU–GPU thuần túy.
- RF Covertypes chỉ đại diện cho configuration cuML đã thử nghiệm.

Appendix: Đóng góp nhóm và tài liệu chính

[HỌ TÊN – MSSV]	Dữ liệu, baseline và kiểm thử
[HỌ TÊN – MSSV]	Benchmark model và Kaggle GPU
[HỌ TÊN – MSSV]	CCP, HS và phân tích
[HỌ TÊN – MSSV]	Report, slide và tổng hợp kết quả

Tài liệu chính: Breiman et al. (1984), *Classification and Regression Trees*; Agarwal et al. (2022), *Hierarchical Shrinkage*; Quinlan (1986, 1993); UCI Letter Recognition và Coverttype; scikit-learn Digits; RAPIDS cuML.

Điền tên, MSSV và điều chỉnh đóng góp đúng thực tế trước khi nộp.