

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

LAB 2

DECISION TREE MODELING AND IMPROVEMENT

Giảng viên: [GIẢNG VIÊN]

Sinh viên: [HỌ TÊN - MSSV]

[HỌ TÊN - MSSV]

[HỌ TÊN - MSSV]

[HỌ TÊN - MSSV]

Mục lục

1	Thực nghiệm và phân tích kết quả	1
1.1	Mục tiêu và thiết lập thực nghiệm	1
1.2	Chỉ số đánh giá và các notebook	2
1.3	Kết quả so sánh bốn mô hình	2
1.4	Kết quả Hierarchical Shrinkage	3
1.5	Độ ổn định và khả năng mở rộng trên Covertypes	5
1.6	Thời gian chạy và nhận xét về GPU	5
1.7	Kết luận thực nghiệm	6

Chương 1

Thực nghiệm và phân tích kết quả

1.1 Mục tiêu và thiết lập thực nghiệm

Thực nghiệm được thiết kế để trả lời ba câu hỏi: Decision Tree đơn hoạt động thế nào trên các dạng dữ liệu khác nhau, các mô hình ensemble/kernel/neighborhood có cải thiện chất lượng dự đoán không, và Hierarchical Shrinkage có giúp giảm overfitting mà vẫn giữ cấu trúc cây hay không. Ba bộ dữ liệu có đặc điểm khác nhau: Letter Recognition là dữ liệu đặc trưng đã trích xuất, Handwritten Digits là biểu diễn điểm ảnh 8×8 , còn Covertypes là bộ dữ liệu lớn dùng để đánh giá khả năng mở rộng.

Các notebook được chạy trên Kaggle. Theo cấu hình phiên chạy, môi trường được đặt ở chế độ Kaggle GPU x2 với 4 CPU logic. Tuy nhiên, metadata trong các artifact ghi nhận từng thiết bị thực tế như sau: các notebook Decision Tree và Hierarchical Shrinkage nhìn thấy Tesla P100-PCIE-16GB nhưng mô hình scikit-learn/imodels chạy trên CPU; notebook benchmark tổng hợp ghi nhận Tesla T4 với 14.911 MB bộ nhớ trống đầu phiên và CUDA runtime 12.090. Ba mô hình Random Forest, SVM và KNN trong notebook tổng hợp chạy bằng cuML trên GPU, còn Decision Tree exact vẫn chạy CPU. Artifact không ghi nhận việc phân bổ hai GPU song song, do đó báo cáo không quy toàn bộ thời gian cho hai GPU.

Tất cả benchmark trong notebook tổng hợp dùng cùng một train/test split cho từng bộ dữ liệu, `test_size=0.20`, `random_state=42` và phân tầng theo nhãn. Letter dùng canonical split đã tiền xử lý gồm 14.934 mẫu train và 3.734 mẫu test. Digits và Covertypes được chia lại theo protocol trên; Covertypes dùng toàn bộ 581.012 mẫu. Tập test chỉ được dùng để báo cáo cuối cùng, không dùng để chọn siêu tham số.

Bảng 1.1: Vai trò và quy mô các bộ dữ liệu

Bộ dữ liệu	Vai trò	Số mẫu	Đặc trưng	Số lớp
Letter Recognition	Đặc trưng hình học chữ cái; split canonical	18.668	16	26
Handwritten Digits	Điểm ảnh 8×8 ; kiểm tra khả năng khái quát	1.797	64	10
Covertypes	Dữ liệu lớn; kiểm tra khả năng mở rộng	581.012	54	7

Letter Recognition đã loại 1.332 dòng trùng chính xác trước khi chia dữ liệu, còn 18.668 mẫu. Các giá trị bị quy tắc IQR đánh dấu vẫn được giữ vì chúng nằm trong miền hợp lệ 0–15 của bộ dữ liệu. Decision Tree và Random Forest không cần chuẩn hóa; SVM và

KNN dùng `StandardScaler` chỉ fit trên tập train.

1.2 Chỉ số đánh giá và các notebook

Chất lượng dự đoán được đánh giá bằng accuracy, error rate và macro-F1. Macro-F1 được ưu tiên khi phân bố lớp không cân bằng vì mỗi lớp đóng góp như nhau vào giá trị trung bình. Khoảng cách giữa accuracy train và test được dùng làm dấu hiệu overfitting. Độ sâu và số lá phản ánh độ phức tạp của cây; thời gian nạp dữ liệu, fit, dự đoán và toàn pipeline phản ánh chi phí tính toán.

Notebook 01 và 02 đánh giá Decision Tree baseline trên Letter Recognition và Digits. Notebook 03 tập trung vào khả năng mở rộng của Decision Tree trên Covertypes, gồm hold-out và 5-fold cross-validation. Notebook 04 so sánh E0 baseline, E1 pre-pruning, E2 cost-complexity pruning, E3 Hierarchical Shrinkage trên baseline và E4 kết hợp CCP với HS. Notebook 05 chạy trong một lần cả Decision Tree exact và ba mô hình GPU trên cả ba bộ dữ liệu, sau đó sinh bảng và biểu đồ so sánh.

1.3 Kết quả so sánh bốn mô hình

Bảng 1.2 tóm tắt kết quả test của notebook 05. Accuracy train của Letter và Covertypes được tính trên một mẫu chẩn đoán cố định 10.000 mẫu để tránh chi phí dự đoán toàn bộ tập train cho KNN; Digits dùng toàn bộ 1.437 mẫu train. Quy ước này được áp dụng cho cả bốn mô hình trong notebook 05.


Bảng 1.2: So sánh bốn mô hình trên ba bộ dữ liệu

Dataset	Model/device	Accuracy	Macro-F1	Gap	Fit (s)	Predict (s)
Letter	Decision Tree / CPU	0,8677	0,8677	0,1323	0,0835	0,0009
Letter	Random Forest / GPU	0,9513	0,9512	0,0449	3,0939	0,0026
Letter	SVM (RBF) / GPU	0,9231	0,9232	0,0253	3,6594	0,0473
Letter	KNN / GPU	0,9408	0,9408	0,0286	0,0017	0,0037
Digits	Decision Tree / CPU	0,8250	0,8230	0,1750	0,0205	0,0003
Digits	Random Forest / GPU	0,9694	0,9689	0,0306	0,6274	0,0009
Digits	SVM (RBF) / GPU	0,9722	0,9718	0,0243	0,7066	0,0117
Digits	KNN / GPU	0,9639	0,9634	0,0201	0,0015	0,0015
Covertypes	Decision Tree / CPU	0,9389	0,9034	0,0611	7,3728	0,0361
Covertypes	Random Forest / GPU	0,7957	0,6586	0,0096	2,9540	0,0412
Covertypes	SVM (RBF) / GPU	0,7907	0,6378	-0,0031	110,4438	15,1030
Covertypes	KNN / GPU	0,9284	0,8732	0,0283	0,0050	5,7506


Trên Letter Recognition, Random Forest đạt kết quả tốt nhất với accuracy 0,9513 và macro-F1 0,9512, cao hơn Decision Tree lần lượt 0,0836 và 0,0836. Trên Digits, SVM đạt macro-F1 cao nhất là 0,9718, chỉ nhỉnh hơn Random Forest 0,0029 điểm. Kết quả này cho thấy ensemble và kernel phù hợp hơn cây đơn khi biểu diễn dữ liệu là các đặc trưng điểm ảnh.

Covertypes cho kết quả khác: Decision Tree có macro-F1 cao nhất trong bốn mô hình ở notebook 05 với 0,9034, còn KNN đạt 0,8732. Random Forest và SVM có khoảng cách train-test nhỏ nhưng chất lượng test thấp hơn nhiều; vì vậy gap nhỏ không đồng nghĩa với mô hình tốt hơn. KNN có thời gian fit gần như bằng 0 vì là lazy learner, nhưng thời gian

dự đoán trên Covertypes là 5,7506 giây. SVM là mô hình chậm nhất với tổng fit và predict khoảng 125,55 giây.



Hình 1.1: Accuracy và macro-F1 của bốn mô hình trên ba bộ dữ liệu.



Hình 1.2: Generalization gap và thời gian fit cộng dự đoán trên notebook benchmark.

1.4 Kết quả Hierarchical Shrinkage

Notebook 04 chọn cấu hình bằng 3-fold cross-validation trên train. E0 là cây baseline, E1 giới hạn trước bằng pre-pruning, E2 dùng cost-complexity pruning, E3 áp dụng HS lên cây baseline và E4 áp dụng HS lên cây CCP. Lambda được chọn theo macro-F1 CV; tập test chỉ dùng cho đánh giá cuối.

Bảng 1.3: Hierarchical Shrinkage trên Letter Recognition

Cấu hình	Accuracy	Macro-F1	Gap	Độ sâu	Lá
E0 Baseline	0,8677	0,8677	0,1323	31	1.965
E1 Pre-pruned	0,8321	0,8348	0,0886	16	1.284
E2 CCP-pruned	0,8677	0,8677	0,1323	31	1.965
E3 HS-DT ($\lambda = 10$)	0,8688	0,8688	0,1263	31	1.965
E4 CCP+HS ($\lambda = 10$)	0,8688	0,8688	0,1263	31	1.965


Bảng 1.4: Hierarchical Shrinkage trên Handwritten Digits


Cấu hình	Accuracy	Macro-F1	Gap	Độ sâu	Lá
E0 Baseline	0,8250	0,8230	0,1750	14	142
E1 Pre-pruned	0,8083	0,8072	0,1304	8	81
E2 CCP-pruned	0,8139	0,8133	0,1235	10	64
E3 HS-DT ($\lambda = 10$)	0,8222	0,8206	0,1750	14	142
E4 CCP+HS ($\lambda = 0$)	0,8167	0,8159	0,1207	10	64

Bảng 1.5: Hierarchical Shrinkage trên Coverttype

Cấu hình	Accuracy	Macro-F1	Gap	Độ sâu	Lá
E0 Baseline	0,9389	0,9034	0,0611	41	23.956
E1 Pre-pruned	0,9297	0,8885	0,0410	40	16.637
E2 CCP-pruned	0,9392	0,9045	0,0507	39	16.361
E3 HS-DT ($\lambda = 10$)	0,9397	0,9048	0,0570	41	23.956
E4 CCP+HS ($\lambda = 10$)	0,9393	0,9053	0,0504	39	16.361

HS cải thiện nhẹ trên Letter: E3/E4 tăng macro-F1 từ 0,8677 lên 0,8688. Trên Digits, HS không cải thiện baseline; E3 đạt 0,8206 và E4 đạt 0,8159 macro-F1. Trên Coverttype, E4 đạt macro-F1 cao nhất 0,9053, tăng 0,0019 so với E0, đồng thời giữ cây ở 16.361 lá thay vì 23.956 lá, giảm khoảng 31,7%. E3 đạt accuracy cao nhất 0,9397 nhưng không giảm độ phức tạp. Các kiểm tra trong notebook cho thấy cấu trúc underlying tree của E3/E4 không đổi sau bước shrinkage; cải thiện đến từ việc điều chỉnh giá trị dự đoán tại nút, không phải từ việc thêm nhánh.

**Hình 1.3:** So sánh hiệu năng các cấu hình Decision Tree và Hierarchical Shrinkage.



Hình 1.4: Quan hệ giữa macro-F1, độ phức tạp cây và generalization gap.


1.5 Độ ổn định và khả năng mở rộng trên Coverytype

Notebook 03 dùng 5-fold cross-validation trên tập train để kiểm tra độ ổn định của baseline và cấu hình regularized. Kết quả được trình bày dưới dạng trung bình $\pm$ độ lệch chuẩn.

Bảng 1.6: Kết quả 5-fold cross-validation trên Coverytype

Mô hình	Accuracy	Macro-F1	Fit time (giây)
Baseline	0,9330 $\pm$ 0,0011	0,8923 $\pm$ 0,0011	8,6710 $\pm$ 0,0852
Regularized	0,8966 $\pm$ 0,0019	0,8388 $\pm$ 0,0028	7,4213 $\pm$ 0,1392

Độ lệch chuẩn nhỏ cho thấy kết quả ổn định giữa các fold. Baseline cao hơn regularized 0,0364 điểm accuracy và 0,0535 điểm macro-F1, trong khi fit time trung bình chỉ tăng khoảng 1,25 giây mỗi fold. Kết quả này phù hợp với hold-out: cắt tỉa mạnh làm cây gọn hơn nhưng mất chất lượng dự đoán.



Hình 1.5: Đánh đổi giữa hiệu năng hold-out và độ phức tạp trên Coverytype.

1.6 Thời gian chạy và nhận xét về GPU

Notebook 05 có tổng thời gian pipeline 173,38 giây, trong đó nạp dữ liệu mất 4,26 giây. Trên Coverytype, Random Forest GPU hoàn tất fit và dự đoán trong khoảng 3,00 giây, nhanh

hơn Decision Tree CPU khoảng 2,5 lần trong phạm vi benchmark này. Tuy nhiên, đây là so sánh giữa hai backend và hai kiểu triển khai khác nhau, không phải phép đo speedup thuần do GPU; vì vậy kết luận chính là GPU giúp các model cuML chạy được trong thời gian ngắn trên bộ dữ liệu lớn, còn chất lượng phải được xem đồng thời.

Bảng 1.7: Thời gian của các mô hình trên Covertypes trong notebook 05

Mô hình	Thiết bị	Fit (s)	Predict (s)	Tổng (s)
Decision Tree	CPU	7,3728	0,0361	7,4089
Random Forest	GPU/Tesla T4	2,9540	0,0412	2,9952
SVM (RBF)	GPU/Tesla T4	110,4438	15,1030	125,5468
KNN	GPU/Tesla T4	0,0050	5,7506	5,7556

KNN minh họa rõ sự khác biệt giữa eager learner và lazy learner: fit gần như không tốn thời gian nhưng prediction tăng theo số điểm train và số điểm test. SVM RBF có chất lượng thấp nhất trên Covertypes trong benchmark này và cũng là mô hình tốn thời gian nhất. Do đó, khi chọn mô hình cho dữ liệu lớn không nên chỉ nhìn vào khả năng sử dụng GPU; cần đánh giá cả macro-F1, thời gian suy luận và mức cân bằng giữa train-test.

1.7 Kết luận thực nghiệm

Decision Tree là baseline dễ diễn giải và có thời gian fit ngắn, nhưng có xu hướng overfit rõ trên Letter và Digits. Random Forest là lựa chọn tốt nhất trên Letter, SVM đạt kết quả tốt nhất trên Digits, còn Decision Tree và các biến thể HS vẫn cạnh tranh trên Covertypes. Với mục tiêu cân bằng chất lượng và độ phức tạp trên Covertypes, E4 CCP+HS là cấu hình đáng chú ý: macro-F1 0,9053 cao hơn E0 và số lá giảm khoảng 31,7%.

GPU của Kaggle được sử dụng hiệu quả cho Random Forest, SVM và KNN thông qua cuML; Decision Tree exact và Hierarchical Shrinkage vẫn được ghi nhận là CPU để không thay đổi thuật toán nghiên cứu. Kết quả cho thấy lựa chọn mô hình phụ thuộc mạnh vào dạng dữ liệu: không có một mô hình duy nhất tốt nhất trên cả ba bộ dữ liệu. Vì vậy, kết luận cuối cần dựa trên macro-F1, generalization gap, runtime và độ phức tạp cùng lúc thay vì chỉ tối ưu accuracy.