

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

LAB 2
DECISION TREE MODELING
AND IMPROVEMENT

Giảng viên: [GIẢNG VIÊN]
Sinh viên: [HỌ TÊN - MSSV]
[HỌ TÊN - MSSV]
[HỌ TÊN - MSSV]
[HỌ TÊN - MSSV]

Tóm tắt

Nghiên cứu này đánh giá Decision Tree trên ba bài toán phân loại đa lớp có quy mô và cấu trúc khác nhau: Letter Recognition, Handwritten Digits và Covertypes. Decision Tree được so sánh với Random Forest, Support Vector Machine và K-Nearest Neighbors theo một quy trình chia dữ liệu và hệ chỉ số thống nhất. Bên cạnh accuracy và macro-F1, nghiên cứu theo dõi train-test gap, thời gian thực thi và độ phức tạp của cây nhằm đánh giá đồng thời chất lượng dự đoán, overfitting và khả năng triển khai.

Kết quả cho thấy không có mô hình tốt nhất trong mọi điều kiện. Random Forest dẫn đầu trên Letter Recognition, SVM đạt kết quả cao nhất trên Digits, trong khi Decision Tree tốt nhất trên Covertypes ở cấu hình khảo sát. Để giảm hạn chế overfitting của cây đơn, nhóm áp dụng Hierarchical Shrinkage (HS), đồng thời kết hợp HS với Cost-Complexity Pruning (CCP). Trên Covertypes, cấu hình CCP + HS tăng nhẹ macro-F1, giảm train-test gap khoảng 17.6% và giảm số lá khoảng 31.7% so với cây cơ sở. Kết quả cho thấy cải tiến đem lại sự cân bằng tốt hơn giữa hiệu năng, khả năng tổng quát hóa và độ phức tạp, dù lợi ích không đồng đều trên các bộ dữ liệu nhỏ.

Từ khóa: Decision Tree, Hierarchical Shrinkage, Cost-Complexity Pruning, phân loại đa lớp, GPU, Covertypes.

Mục lục

Tóm tắt	i
1 Giới thiệu	1
2 Dữ liệu nghiên cứu	3
3 Phương pháp nghiên cứu	5
4 Kết quả và thảo luận	7
5 Cải tiến Decision Tree bằng Hierarchical Shrinkage	12
6 Kết luận và hướng phát triển	17
Tài liệu tham khảo	18

Chương 1

Giới thiệu

1.1 Bối cảnh và vấn đề nghiên cứu

Decision Tree là mô hình học máy phổ biến nhờ khả năng diễn giải trực quan, không đòi hỏi chuẩn hóa đặc trưng và có thể biểu diễn các quan hệ phi tuyến [1]. Mỗi dự đoán có thể được truy vết qua một chuỗi điều kiện, vì vậy mô hình phù hợp với các bài toán cần giải thích quyết định. Tuy nhiên, một cây đơn thường nhạy với dữ liệu huấn luyện, dễ phát triển quá sâu và dẫn đến overfitting. Cùng một cấu hình cũng có thể cho hiệu quả rất khác nhau khi quy mô, số chiều hoặc phân bố lớp thay đổi.

Từ vấn đề đó, nghiên cứu tập trung vào câu hỏi tổng quát: *Decision Tree hoạt động như thế nào trên các bộ dữ liệu có cấu trúc khác nhau, và có thể cải thiện khả năng tổng quát hóa của cây mà vẫn duy trì tính diễn giải hay không?*

1.2 Câu hỏi nghiên cứu

Ba câu hỏi nghiên cứu được đặt ra:

- **RQ1:** Hiệu năng của Decision Tree thay đổi như thế nào giữa dữ liệu nhiều lớp, dữ liệu ảnh ít mẫu và dữ liệu bảng quy mô lớn?
- **RQ2:** So với Random Forest, SVM và KNN, Decision Tree có ưu thế và hạn chế gì về chất lượng dự đoán, overfitting và thời gian chạy?
- **RQ3:** Hierarchical Shrinkage, khi sử dụng riêng hoặc kết hợp Cost-Complexity Pruning, cải thiện những khía cạnh nào của Decision Tree?

1.3 Mục tiêu và đóng góp

Nghiên cứu hướng tới các mục tiêu sau:

- xây dựng quy trình thực nghiệm thống nhất cho ba bài toán phân loại đa lớp;
- đánh giá mô hình theo accuracy, macro-F1, train-test gap, độ phức tạp và thời gian chạy;
- so sánh Decision Tree với ba mô hình đối chứng đại diện cho ensemble, kernel và phương pháp dựa trên khoảng cách;

- kiểm tra khả năng mở rộng trên Covertypes với hơn nửa triệu mẫu;
- đánh giá định lượng tác động của HS và CCP lên dự đoán, overfitting và cấu trúc cây.

Đóng góp chính của nghiên cứu là một phân tích thực nghiệm thống nhất trên ba kiểu dữ liệu, đi kèm đánh giá rõ ràng về giới hạn của từng mô hình. Đối với cải tiến Decision Tree, nghiên cứu tách biệt vai trò của HS trong việc làm mượt dự đoán và vai trò của CCP trong việc giảm độ phức tạp cấu trúc.

1.4 Cấu trúc báo cáo

Chương 2 trình bày dữ liệu và lý do lựa chọn. Chương 3 mô tả mô hình, quy trình thực nghiệm, chỉ số và môi trường tính toán. Chương 4 báo cáo kết quả so sánh và thảo luận. Chương 5 trình bày phương pháp cải tiến Decision Tree và phân tích tác động của HS kết hợp CCP. Chương 6 tổng kết các phát hiện, giới hạn và hướng phát triển.

Chương 2

Dữ liệu nghiên cứu

2.1 Tiêu chí lựa chọn

Ba bộ dữ liệu được chọn nhằm tạo ra các điều kiện thực nghiệm khác biệt về số mẫu, số thuộc tính, số lớp và bản chất đặc trưng. Thiết kế này giúp tránh việc đưa ra kết luận chỉ từ các bộ dữ liệu nhỏ hoặc có cấu trúc tương đồng. Letter Recognition đại diện cho phân loại nhiều lớp với đặc trưng hình học; Digits đại diện cho dữ liệu ảnh nhiều chiều nhưng ít mẫu; Covertypes đại diện cho dữ liệu bảng quy mô lớn và phân bố lớp không đều.

Bảng 2.1: Đặc trưng của ba bộ dữ liệu sau bước chuẩn bị dữ liệu.

Bộ dữ liệu	Mẫu	Thuộc tính	Lớp	Train/Test	Tính chất chính
Letter Recognition	18,668	16	26	14,934 / 3,734	Đặc trưng hình học số nguyên, phân loại nhiều lớp
Handwritten Digits	1,797	64	10	1,437 / 360	Ảnh xám 8×8 được trải phẳng, dữ liệu nhỏ và nhiều chiều
Covertypes	581,012	54	7	464,809 / 116,203	Quy mô lớn, thuộc tính số và nhị phân, phân bố lớp không đều

2.2 Letter Recognition

Letter Recognition mô tả 26 chữ cái in hoa bằng 16 thuộc tính hình học đã trích xuất, chẳng hạn kích thước hộp bao, vị trí và phân bố điểm ảnh [6]. Các giá trị thuộc tính nằm trong khoảng từ 0 đến 15. Sau khi loại 1,332 dòng trùng hoàn toàn, bộ dữ liệu còn 18,668 mẫu.

Bộ dữ liệu này phù hợp vì có nhiều lớp nhưng số thuộc tính vừa phải. Nó giúp kiểm tra khả năng tạo ranh giới quyết định cho bài toán đa lớp và cho thấy sự khác biệt giữa một cây đơn, mô hình tập hợp và mô hình dựa trên khoảng cách. Việc loại trùng trước khi chia dữ liệu tránh trường hợp cùng một quan sát xuất hiện ở cả train và test, làm kết quả lạc quan giả tạo.

2.3 Handwritten Digits

Handwritten Digits gồm 1,797 ảnh chữ số viết tay từ 0 đến 9. Mỗi ảnh 8×8 được biểu diễn bởi 64 mức cường độ điểm ảnh [7]. So với Letter Recognition, dữ liệu có ít mẫu hơn nhưng số chiều cao hơn và các thuộc tính mang cấu trúc không gian của ảnh.

Bộ dữ liệu này kiểm tra mô hình trong điều kiện tập huấn luyện nhỏ. Đây cũng là trường hợp phù hợp để quan sát lợi thế của SVM và KNN khi các lớp tạo thành những cụm tương đối rõ trong không gian đặc trưng, đồng thời bộc lộ hạn chế của phép chia theo từng trục của Decision Tree.

2.4 Covertypes

Covertypes gồm 581,012 mẫu, 54 thuộc tính và 7 loại lớp phủ rừng [8]. Các thuộc tính kết hợp biến liên tục về địa hình với biến nhị phân mô tả khu vực hoang dã và loại đất. Số lượng mẫu giữa các lớp không đồng đều, vì vậy macro-F1 có ý nghĩa đặc biệt quan trọng bên cạnh accuracy.

Đây là bộ dữ liệu phù hợp nhất để đánh giá khả năng mở rộng, chi phí dự đoán và hiệu quả của phương pháp cải tiến. Với tập test gồm 116,203 mẫu, thay đổi nhỏ về hiệu năng có cơ sở thực nghiệm rõ hơn; đồng thời độ sâu và số lá lớn của cây cơ sở làm tác động của regularization dễ quan sát.

2.5 Chuẩn bị dữ liệu

Tất cả thí nghiệm sử dụng `test_size=0.20`, `random_state=42` và chia phân tầng theo nhãn. Letter Recognition sử dụng đúng tập train/test được tạo sau bước loại trùng. StandardScaler chỉ được fit trên tập train và chỉ áp dụng cho SVM, KNN; Decision Tree và Random Forest sử dụng đặc trưng gốc. Tập test chỉ được dùng để báo cáo kết quả cuối cùng, không tham gia chọn siêu tham số.

Chương 3

Phương pháp nghiên cứu

3.1 Thiết kế thực nghiệm

Mỗi bộ dữ liệu được đánh giá theo cùng một quy trình: chuẩn bị dữ liệu, tạo phép chia train/test cố định, huấn luyện bốn mô hình, dự đoán trên tập test và lưu toàn bộ chỉ số cùng hình trực quan. Quy trình chung giúp giảm ảnh hưởng của khác biệt tiền xử lý khi so sánh mô hình. Riêng các tham số regularization của Decision Tree được lựa chọn bằng cross-validation trên tập train.

3.2 Các mô hình so sánh

3.2.1 Decision Tree

Decision Tree là mô hình trung tâm của nghiên cứu và được xây dựng theo nền tảng CART [1]. Mô hình dễ diễn giải, không cần chuẩn hóa và huấn luyện nhanh. Nhược điểm chính là phương sai cao: cây có thể ghi nhớ dữ liệu, phát triển nhiều nhánh sâu và thay đổi đáng kể trước biến động nhỏ của tập huấn luyện.

3.2.2 Random Forest

Random Forest kết hợp nhiều cây được huấn luyện trên các mẫu và tập thuộc tính khác nhau [2]. Cơ chế ensemble thường giảm phương sai và tổng quát hóa tốt hơn cây đơn. Đổi lại, mô hình lớn hơn, khó diễn giải ở mức từng quyết định và cần nhiều tài nguyên tính toán hơn.

3.2.3 Support Vector Machine

SVM với RBF kernel tạo biên phân lớp phi tuyến và thường hoạt động tốt trên dữ liệu nhỏ hoặc trung bình có số chiều cao [3]. Mô hình cần chuẩn hóa đặc trưng, khó diễn giải trực tiếp và chi phí tính toán có thể tăng mạnh theo số mẫu.

3.2.4 K-Nearest Neighbors

KNN phân loại dựa trên nhãn của các điểm gần nhất [4]. Mô hình gần như không có giai đoạn học tham số và khai thác tốt cấu trúc lân cận. Hạn chế là cần lưu tập train, nhạy với

thang đo và có chi phí dự đoán tăng theo kích thước dữ liệu.

3.3 Chỉ số đánh giá

Nghiên cứu sử dụng các chỉ số sau:

- **Accuracy** đo tỷ lệ dự đoán đúng trên toàn bộ tập test;
- **Macro-F1** tính F1 độc lập cho từng lớp rồi lấy trung bình, nhờ đó hạn chế việc lớp lớn lấn át lớp nhỏ;
- **Train-test gap** là chênh lệch accuracy giữa train và test, dùng như tín hiệu thực nghiệm của overfitting;
- **Thời gian fit và predict** phản ánh chi phí thực thi;
- **Độ sâu và số lá** mô tả độ phức tạp của Decision Tree.

Với Letter Recognition và Covertypes, train accuracy trong notebook so sánh được đo trên cùng một mẫu chuẩn đoán cố định gồm 10,000 quan sát cho cả bốn mô hình; Digits dùng toàn bộ tập train.

3.4 Môi trường tính toán

Decision Tree chạy bằng scikit-learn trên CPU [9]. Random Forest, SVM và KNN trong notebook so sánh sử dụng RAPIDS cuML trên GPU [10]. Phiên Kaggle được cấu hình GPU x2 theo môi trường chạy của nhóm; tệp kết quả ghi nhận thiết bị tính toán của cuML là Tesla T4 với khoảng 14.9 GB bộ nhớ khả dụng. Các kết quả riêng của Decision Tree và HS ghi nhận Tesla P100 16 GB khả dụng nhưng mô hình vẫn chạy trên CPU.

Do backend và thuật toán khác nhau, thời gian trong nghiên cứu được hiểu là chi phí thực tế của từng pipeline. Các con số này không phải phép đo speedup CPU-GPU thuần túy và không chứng minh hai GPU được sử dụng song song trong mọi thí nghiệm.

3.5 Nguyên tắc bảo đảm tính công bằng

Các mô hình sử dụng cùng phép chia dữ liệu và cùng tập test. Bộ chuẩn hóa chỉ học từ tập train để tránh rò rỉ dữ liệu. Random state được cố định nhằm bảo đảm khả năng tái lập. Kết luận về mô hình chỉ giới hạn trong cấu hình và implementation được khảo sát; nghiên cứu không suy rộng rằng một họ thuật toán luôn vượt họ thuật toán khác.

Chương 4

Kết quả và thảo luận

4.1 Kết quả tổng hợp

Kết quả được trình bày riêng cho từng bộ dữ liệu nhằm bảo đảm bảng và hình có kích thước đủ lớn để đọc. Trong mỗi tiểu mục, bảng cung cấp giá trị chính xác còn biểu đồ hỗ trợ so sánh trực quan giữa các mô hình. Giá trị in đậm là kết quả tốt nhất trên bộ dữ liệu tương ứng.

4.2 Phân tích theo từng bộ dữ liệu

4.2.1 Letter Recognition

Bảng 4.1: Kết quả của bốn mô hình trên Letter Recognition.

Mô hình	Accuracy	Macro-F1	Tổng thời gian (s)
Decision Tree (CPU)	0.8677	0.8677	0.0844
Random Forest (GPU)	0.9513	0.9512	3.0965
SVM-RBF (GPU)	0.9231	0.9232	3.7067
KNN (GPU)	0.9408	0.9408	0.0055




Hình 4.1: Accuracy và macro-F1 của bốn mô hình trên Letter Recognition.

Random Forest đạt kết quả tốt nhất với accuracy 0.9513 và macro-F1 0.9512. KNN đứng thứ hai, cho thấy các chữ cái có cấu trúc lân cận hữu ích. Decision Tree có thời gian chạy ngắn nhưng kém RF 8.36 điểm phần trăm accuracy và có train-test gap 0.1323, thể hiện overfitting rõ. Trên dữ liệu nhiều lớp này, việc kết hợp nhiều cây giúp RF giảm phương sai hiệu quả hơn một cây đơn.

4.2.2 Handwritten Digits

Bảng 4.2: Kết quả của bốn mô hình trên Handwritten Digits.

Mô hình	Accuracy	Macro-F1	Tổng thời gian (s)
Decision Tree (CPU)	0.8250	0.8230	0.0207
Random Forest (GPU)	0.9694	0.9689	0.6282
SVM-RBF (GPU)	0.9722	0.9718	0.7183
KNN (GPU)	0.9639	0.9634	0.0030




Hình 4.2: Accuracy và macro-F1 của bốn mô hình trên Handwritten Digits.

SVM đạt accuracy 0.9722 và macro-F1 0.9718, nhỉnh hơn RF và KNN. Kết quả phù hợp với ưu thế của RBF kernel trên dữ liệu ảnh nhỏ, nhiều chiều. Decision Tree chỉ đạt accuracy 0.8250 do một cây đơn khó biểu diễn hình dạng chữ số bằng các phép chia theo từng thuộc tính. KNN cũng hoạt động tốt vì các chữ số tương tự tạo thành các lân cận có ý nghĩa.

4.2.3 Covertypes

Bảng 4.3: Kết quả của bốn mô hình trên Covertypes.


Mô hình	Accuracy	Macro-F1	Tổng thời gian (s)
Decision Tree (CPU)	0.9389	0.9034	7.4089
Random Forest (GPU)	0.7957	0.6586	2.9952
SVM-RBF (GPU)	0.7907	0.6378	125.5468
KNN (GPU)	0.9284	0.8732	5.7556




Hình 4.3: Accuracy và macro-F1 của bốn mô hình trên Covertypes.

Decision Tree đạt kết quả cao nhất với accuracy 0.9389 và macro-F1 0.9034; KNN đứng thứ hai. SVM mất 125.55 giây nhưng chỉ đạt accuracy 0.7907, cho thấy GPU không khắc phục được sự không phù hợp giữa cấu hình mô hình và dữ liệu. Random Forest cũng thấp hơn kỳ vọng trong cấu hình cuML hiện tại. Kết luận này chỉ áp dụng cho siêu tham số và implementation đã báo cáo, không khẳng định DT luôn vượt RF hoặc SVM.

4.3 Overfitting và chi phí tính toán



Hình 4.4: Train-test gap của từng mô hình trên ba bộ dữ liệu.



Hình 4.5: Thời gian huấn luyện và dự đoán trên toàn bộ tập test; trục tung dùng thang logarithm.

Decision Tree có train-test gap lớn nhất trên Letter và Digits, lần lượt khoảng 0.132 và 0.175. Đây là bằng chứng cho hạn chế phương sai cao của cây đơn. Trên Covertypes, gap của Decision Tree giảm còn khoảng 0.061 nhờ lượng dữ liệu huấn luyện lớn, nhưng cây cơ sở trở nên rất phức tạp. KNN có thời gian fit gần như bằng không nhưng thời gian dự đoán tăng rõ trên Covertypes. SVM là lựa chọn cạnh tranh trên Digits nhưng trở thành mô hình chậm nhất trên dữ liệu lớn.

4.4 Kiểm tra độ ổn định trên Covertypes

Thí nghiệm 5-fold cross-validation độc lập cho Decision Tree cơ sở thu được accuracy 0.9330 ± 0.0011 và macro-F1 0.8923 ± 0.0011 . Độ lệch chuẩn nhỏ cho thấy kết quả tương đối ổn định giữa các fold. Một cấu hình regularization đặt trước giảm thời gian fit trung bình từ 8.67 xuống 7.42 giây nhưng làm accuracy giảm còn 0.8966 ± 0.0019 . Kết quả cho thấy regularization quá mạnh có thể gây underfit và cần được chọn bằng validation thay vì áp dụng tùy ý.

4.5 Trả lời RQ1 và RQ2

Đối với RQ1, Decision Tree phù hợp nhất với Covertypes trong cấu hình hiện tại, nhưng kém rõ rệt trên Letter và Digits. Lượng dữ liệu lớn giúp cây học các phân vùng chi tiết, trong khi dữ liệu ảnh hoặc dữ liệu ít mẫu làm hạn chế của phép chia theo trục bậc lộ rõ hơn. Đối với RQ2, Decision Tree có lợi thế về tính diễn giải và tốc độ huấn luyện, nhưng Random Forest, SVM hoặc KNN có thể đạt chất lượng tốt hơn tùy cấu trúc dữ liệu. Chi phí GPU và độ chính xác không có quan hệ đơn điệu; lựa chọn mô hình vẫn phải dựa trên đặc điểm bài toán.

Chương 5

Cải tiến Decision Tree bằng Hierarchical Shrinkage

5.1 Động cơ lựa chọn phương pháp

Kết quả ở Chương 4 cho thấy Decision Tree có train-test gap lớn trên hai bộ dữ liệu nhỏ và tạo cây rất phức tạp trên Covertypes. Nhóm chọn Hierarchical Shrinkage vì phương pháp này regularize trực tiếp dự đoán của một cây đã huấn luyện mà không phá vỡ cấu trúc phân nhánh [5]. Điều này phù hợp với mục tiêu duy trì tính diễn giải của Decision Tree.

5.2 Nguyên lý Hierarchical Shrinkage

HS co ước lượng tại nút con về thông tin của các nút tổ tiên theo hệ số λ [5]. Khi λ tăng, dự đoán giảm phụ thuộc vào các nhánh sâu chứa ít mẫu, qua đó hạn chế xác suất quá tự tin và giảm phương sai. HS không thay đổi thuộc tính chia, độ sâu hoặc số lá; phần được cải tiến là ước lượng dự đoán tại các nút.

Để đồng thời kiểm soát cấu trúc, nhóm kết hợp HS với Cost-Complexity Pruning, một cơ chế cắt tỉa thuộc khung CART [1]. CCP loại các nhánh có đóng góp nhỏ, trực tiếp giảm độ sâu và số lá; HS sau đó làm mượt dự đoán trên cây đã cắt tỉa. Thiết kế này tách rõ ba vai trò:

- **HS** cải thiện khả năng tổng quát hóa mà không thay đổi topology;
- **CCP** giảm độ phức tạp cấu trúc;
- **CCP + HS** cân bằng hiệu năng, overfitting và khả năng diễn giải.


5.3 Thiết kế thí nghiệm cải tiến

Năm cấu hình được đánh giá gồm E0 – cây cơ sở, E1 – pre-pruning, E2 – CCP, E3 – HS và E4 – CCP kết hợp HS. Hệ số λ và mức pruning được chọn bằng 3-fold cross-validation trên tập train. Covertypes được dùng làm dẫn chứng chính vì có 581,012 mẫu và cây cơ sở phát triển tới 23,956 lá.

5.4 Kết quả chính trên Covertypes

Bảng 5.1: Ảnh hưởng của các phương pháp cải tiến trên Covertypes.

ID	Cấu hình	Accuracy	Macro-F1	Gap	Độ sâu	Số lá
E0	Baseline	0.9389	0.9034	0.0611	41	23,956
E1	Pre-pruning	0.9297	0.8885	0.0410	40	16,637
E2	CCP	0.9392	0.9045	0.0507	39	16,361
E3	HS ($\lambda = 10$)	0.9397	0.9048	0.0570	41	23,956
E4	CCP + HS ($\lambda = 10$)	0.9393	0.9053	0.0504	39	16,361




Hình 5.1: Hiệu năng của năm cấu hình Decision Tree trên Covertypes.


So với E0, E3 tăng accuracy từ 0.9389 lên 0.9397 và macro-F1 từ 0.9034 lên 0.9048 trong khi cấu trúc giữ nguyên 41 tầng và 23,956 lá. Kết quả xác nhận HS tác động lên ước lượng dự đoán thay vì cách cây được xây dựng.

E4 cho sự cân bằng tốt nhất. So với baseline, macro-F1 tăng 0.0019, accuracy tăng 0.0005 và train-test gap giảm từ 0.0611 xuống 0.0504, tương đương khoảng 17.6%. Đồng thời, số lá giảm 7,595, tương đương 31.7%, và độ sâu giảm từ 41 xuống 39. E3 có accuracy cao nhất, còn E4 có macro-F1 cao nhất và cấu trúc nhỏ hơn. Do Covertypes mất cân bằng lớp, E4 được xem là cấu hình phù hợp nhất.

5.5 Độ phức tạp và khả năng tổng quát hóa



Hình 5.2: Quan hệ giữa macro-F1 và số lá của từng cấu hình Decision Tree.




Hình 5.3: Train–test gap sau khi áp dụng các cấu hình regularization.

Hai hình được tách riêng để phân biệt hai khía cạnh đánh giá: Hình 5.2 biểu diễn sự đánh đổi giữa hiệu năng và kích thước cây, trong khi Hình 5.3 tập trung vào overfitting. Trên Covertypes, E4 dịch chuyển theo hướng mong muốn: số lá giảm đáng kể, macro-F1 tăng nhẹ và gap thấp hơn baseline.

5.6 Khả năng khái quát trên các bộ dữ liệu khác



Hình 5.4: Hiệu năng của năm cấu hình Decision Tree trên Letter Recognition.



Hình 5.5: Hiệu năng của năm cấu hình Decision Tree trên Handwritten Digits.

HS không tạo mức cải thiện đồng đều. Trên Letter Recognition, HS với $\lambda = 10$ tăng accuracy từ 0.8677 lên 0.8688 và macro-F1 từ 0.8677 lên 0.8688 nhưng không giảm số lá. Trên Digits, HS đạt accuracy 0.8222, thấp hơn baseline 0.8250; CCP + HS giảm số lá từ 142 xuống 64 nhưng macro-F1 chỉ đạt 0.8159.

Các kết quả cho thấy HS phù hợp hơn khi cây có nhiều nhánh sâu và đủ dữ liệu để chọn λ ổn định. Với dữ liệu nhỏ như Digits, lợi ích có thể bị lấn át bởi sai số lấy mẫu. Vì vậy, nghiên cứu không kết luận HS luôn làm tăng accuracy.

5.7 Trả lời RQ3 và thảo luận giới hạn

Đối với RQ3, HS cải thiện phần ước lượng xác suất và có thể giảm train-test gap mà không thay đổi cấu trúc. CCP cải thiện trực tiếp độ gọn của cây. Trên Covertypes, kết hợp hai phương pháp tạo ra cấu hình có macro-F1 tốt nhất, gap thấp hơn và ít lá hơn baseline. Tuy nhiên, mức tăng accuracy và macro-F1 còn nhỏ, kết quả chưa được lặp lại qua nhiều random seed, và lợi ích không xuất hiện trên Digits. Do đó, kết luận mạnh nhất là HS + CCP cải thiện sự cân bằng giữa hiệu năng và độ phức tạp trên dữ liệu lớn, không phải bảo đảm tăng độ chính xác trong mọi bài toán.

Chương 6

Kết luận và hướng phát triển

6.1 Kết luận chính

Nghiên cứu đã đánh giá Decision Tree trên ba bộ dữ liệu đại diện cho ba điều kiện: phân loại nhiều lớp với đặc trưng hình học, ảnh nhiều chiều nhưng ít mẫu và dữ liệu bảng quy mô lớn, mất cân bằng. Không có mô hình nào tốt nhất trong mọi trường hợp. Random Forest dẫn đầu trên Letter Recognition, SVM tốt nhất trên Digits, còn Decision Tree tốt nhất trên Covertypes trong cấu hình hiện tại. KNN có thời gian fit rất nhỏ nhưng chi phí dự đoán tăng trên dữ liệu lớn; SVM cho kết quả tốt ở dữ liệu nhỏ nhưng trở thành mô hình chậm nhất trên Covertypes.

Hierarchical Shrinkage làm mượt dự đoán mà giữ nguyên cấu trúc cây, trong khi CCP trực tiếp loại nhánh. Kết hợp CCP + HS trên Covertypes tăng nhẹ accuracy và macro-F1, giảm train-test gap khoảng 17.6% và giảm số lá khoảng 31.7%. Đây là bằng chứng rõ nhất rằng phương pháp cải tiến đem lại một cây gọn hơn, ít overfitting hơn mà không đánh đổi hiệu năng test.

6.2 Ý nghĩa thực tiễn

Kết quả cho thấy việc lựa chọn mô hình cần dựa trên cấu trúc dữ liệu và yêu cầu triển khai. Decision Tree là lựa chọn hấp dẫn khi cần giải thích và tốc độ huấn luyện, nhưng cần regularization khi cây quá sâu. GPU hữu ích cho các implementation hỗ trợ tăng tốc, song không tự bảo đảm mô hình chính xác hơn hoặc nhanh hơn ở mọi giai đoạn. Trên dữ liệu lớn, chi phí dự đoán và mức phù hợp của thuật toán quan trọng không kém phần cứng.

6.3 Hạn chế và hướng phát triển

Nghiên cứu hiện sử dụng một phép chia chính với random state cố định và không tìm kiếm siêu tham số toàn diện cho tất cả mô hình. Các backend CPU và GPU cũng khác nhau, vì vậy thời gian chạy chưa phải benchmark phần cứng thuần túy. Trong tương lai, thí nghiệm nên được lặp lại với nhiều seed, áp dụng nested cross-validation cho lựa chọn siêu tham số, mở rộng không gian λ và mức pruning, đồng thời đo kích thước mô hình, bộ nhớ và độ trễ dự đoán. Việc bổ sung kiểm định thống kê cũng giúp xác định liệu mức cải thiện nhỏ của HS có ổn định trên nhiều lần lấy mẫu hay không.

Tài liệu tham khảo

- [1] L. Breiman, J. H. Friedman, R. A. Olshen, and C. J. Stone, *Classification and Regression Trees*. Wadsworth International Group, 1984.
- [2] L. Breiman, “Random Forests,” *Machine Learning*, vol. 45, pp. 5–32, 2001. doi: [10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324).
- [3] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, pp. 273–297, 1995. doi: [10.1007/BF00994018](https://doi.org/10.1007/BF00994018).
- [4] T. M. Cover and P. E. Hart, “Nearest neighbor pattern classification,” *IEEE Transactions on Information Theory*, vol. 13, no. 1, pp. 21–27, 1967. doi: [10.1109/TIT.1967.1053964](https://doi.org/10.1109/TIT.1967.1053964).
- [5] A. Agarwal, Y. S. Tan, O. Ronen, C. Singh, and B. Yu, “Hierarchical Shrinkage: Improving the accuracy and interpretability of tree-based methods,” *arXiv preprint arXiv:2202.00858*, 2022. Available: <https://arxiv.org/abs/2202.00858>.
- [6] D. Slate, “Letter Recognition [Dataset],” UCI Machine Learning Repository, 1991. doi: [10.24432/C5ZP40](https://doi.org/10.24432/C5ZP40).
- [7] scikit-learn developers, “load_digits: Digits classification dataset,” *scikit-learn Documentation*. Available: https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_digits.html. Accessed: Aug. 27, 2026.
- [8] J. Blackard, “Covertypes [Dataset],” UCI Machine Learning Repository, 1998. doi: [10.24432/C50K5N](https://doi.org/10.24432/C50K5N).
- [9] F. Pedregosa et al., “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. Available: <https://jmlr.org/papers/v12/pedregosa11a.html>.
- [10] RAPIDS Development Team, “cuML: GPU Machine Learning Algorithms,” *RAPIDS Documentation*. Available: <https://docs.rapids.ai/api/cuml/stable/>. Accessed: Aug. 27, 2026.