

Decision Tree Modeling and Improvement

Từ cây cơ sở đến CCP và Hierarchical Shrinkage

Nhóm thực hiện

[HỌ TÊN – MSSV] [HỌ TÊN – MSSV]

[HỌ TÊN – MSSV] [HỌ TÊN – MSSV]

Introduction to Artificial Intelligence – Lab 2

Trường Đại học Khoa học Tự nhiên – ĐHQG TP.HCM

Sáu chương nổi từ vấn đề đến bằng chứng

- ① Bối cảnh và động lực
- ② Các công trình liên quan
- ③ Kiến thức nền tảng
- ④ Phương pháp nghiên cứu
- ⑤ Thực nghiệm và phân tích kết quả
- ⑥ Kết luận

Từ vấn đề → cơ chế → thực nghiệm → kết luận.

1 | BỐI CẢNH VÀ ĐỘNG LỰC

Cây không giới hạn có thể ghi nhớ tập train và tạo hàng chục nghìn lá.

- Cây đơn dễ đọc vì mỗi đường đi là một luật *if-then*.
- Split tham lam làm cây nhạy với nhiễu và các nhánh ít mẫu.
- Bài toán không chỉ là tăng điểm số, mà còn phải kiểm soát độ phức tạp.

Ba câu hỏi dẫn đường cho toàn bộ nghiên cứu

1 | BỐI CẢNH VÀ ĐỘNG LỰC

RQ1 – Phù hợp dữ liệu

Decision Tree hoạt động thế nào trên dữ liệu đa lớp, ảnh và dữ liệu bảng lớn?

RQ2 – So sánh mô hình

Khi nào cây đơn cạnh tranh được với Random Forest, SVM và KNN?

RQ3 – Cải tiến

Regularization có giảm overfitting mà vẫn giữ hiệu năng và khả năng diễn giải không?

Decision Tree phát triển từ ID3 và C4.5 đến CART

2 | CÁC CÔNG TRÌNH LIÊN QUAN

Thuật toán	Công trình	Đóng góp chính
ID3	Quinlan (1986)	Chọn thuộc tính bằng information gain
C4.5	Quinlan (1993)	Xử lý thuộc tính liên tục và dùng gain ratio
CART	Breiman et al. (1984)	Binary split, Gini impurity và pruning

Nghiên cứu dùng **CART** qua `DecisionTreeClassifier` của `scikit-learn`.

Ba mô hình đối chứng đại diện cho ba cơ chế khác nhau

2 | CÁC CÔNG TRÌNH LIÊN QUAN

Random Forest

Ensemble nhiều cây để giảm phương sai.

SVM-RBF

Tạo ranh giới phi tuyến bằng kernel.

KNN

Dự đoán theo các điểm lân cận.

Đối chứng trả lời câu hỏi: **Decision Tree cơ bản mạnh ở đâu trước khi cải tiến?**

Gini đo mức độ hỗn tạp tại mỗi nút

3 | KIẾN THỨC NỀN TẢNG

$$Gini(S) = 1 - \sum_{k=1}^K p_k^2$$

- p_k là tỷ lệ lớp k trong tập mẫu tại nút.
- $Gini = 0$ khi tất cả mẫu thuộc cùng một lớp.
- CART tìm phép chia làm hai nút con thuần hơn nút cha.

CART chọn split tạo mức giảm Gini lớn nhất

3 | KIẾN THỨC NỀN TẢNG

$$\Delta G(j, t) = Gini(S) - \frac{n_L}{n} Gini(S_L) - \frac{n_R}{n} Gini(S_R)$$
$$(j^*, t^*) = \arg \max_{j, t} \Delta G(j, t)$$

- j là feature; t là threshold.
- Gain lớn nghĩa hai nút con giảm hỗn tạp nhiều nhất.
- Phép chọn tham lam được lặp lại ở từng nút.

Huấn luyện cây là một quá trình đệ quy

3 | KIẾN THỨC NỀN TẢNG

```
BuildTree(S):  
  if Stop(S): return Leaf( $\hat{p}(y | S)$ )  
   $(j^*, t^*) \leftarrow \arg \max_{j,t} \Delta G(j, t)$   
   $S_L, S_R \leftarrow \text{Split}(S, j^*, t^*)$   
  return Node( $j^*, t^*$ ,  
    BuildTree( $S_L$ ), BuildTree( $S_R$ ))
```

Điểm dễ overfit: điều kiện dừng quá lỏng khiến quá trình tiếp tục đến các nhánh rất ít mẫu.

Suy luận chỉ đi qua một đường từ gốc đến lá

3 | KIẾN THỨC NỀN TẢNG

```
Predict( $x, v$ ):  
while  $v$  is not leaf:  
   $v \leftarrow$  left if  $x_j \leq t$   
  else right  
return  $\arg \max_k \hat{p}_k(v)$ 
```

Ba vị trí cải tiến

- Điều kiện dừng.
- Topology sau khi fit.
- Xác suất tại các nút.

Lá ít mẫu có thể tạo xác suất quá cực đoan dù luật suy luận vẫn hợp lệ.

Ba dataset đại diện cho ba cấu trúc dữ liệu

4 | PHƯƠNG PHÁP NGHIÊN CỨU

Dataset	Mẫu	Features	Kiểu kiểm thử
Letter Recognition	18.668	16	Đa lớp, đặc trưng hình học
Handwritten Digits	1.797	64	Ảnh ít mẫu, nhiều chiều
Covertypes	581.012	54	Dữ liệu bảng lớn, mất cân bằng

Covertypes là bài toán chính; Letter và Digits kiểm tra độ bền của kết luận.

Coertype tạo đủ áp lực để đánh giá độ phức tạp cây

4 | PHƯƠNG PHÁP NGHIÊN CỨU

581.012

Mẫu

54

Features

7

Lớp

- Quy mô lớn cho phép cây phát triển nhiều tầng và nhiều lá.
- Phân bố lớp mất cân bằng làm accuracy chưa đủ để đánh giá.
- Dữ liệu bảng phù hợp với các luật split theo feature và threshold.

Vì vậy Coertype được dùng làm **dataset dẫn chứng chính**.

Train và test được tách trước mọi bước lựa chọn mô hình

4 | PHƯƠNG PHÁP NGHIÊN CỨU

Dữ liệu sạch $\longrightarrow$ 80/20 stratified split
 $\longrightarrow$ train $\longrightarrow$ test cuối cùng

- `random_state=42` dùng chung.
- Scaler chỉ fit trên train cho SVM và KNN.
- Cross-validation chỉ truy cập tập train.

Đánh giá cần đồng thời đo chất lượng và độ phức tạp

4 | PHƯƠNG PHÁP NGHIÊN CỨU

Chất lượng dự đoán

- Accuracy
- Error rate
- Macro-F1
- Confusion matrix

Overfitting và triển khai

- Train–test gap
- Độ sâu
- Số lá
- Fit/prediction time

Macro-F1 cho mỗi lớp trọng số ngang nhau; số lá phản ánh trực tiếp khả năng diễn giải.

Baseline E0 là một CART chưa giới hạn độ sâu

4 | PHƯƠNG PHÁP NGHIÊN CỨU

Cấu hình cơ bản

- `criterion=gini`
- `random_state=42`
- Không đặt `max_depth`
- `ccp_alpha=0`

Vai trò của E0

- Đo năng lực của cây chuẩn.
- Làm mốc cho các mô hình đối chứng.
- Bộc lộ overfitting và độ phức tạp.

E0 **chưa dùng** pre-pruning, Cost-Complexity Pruning hay Hierarchical Shrinkage.

Không có mô hình tốt nhất trên mọi dataset


5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ

Dataset	Mô hình tốt nhất	Accuracy	Macro-F1
Letter Recognition	Random Forest	95,13%	95,12%
Handwritten Digits	SVM-RBF	97,22%	97,18%
Covertypes	Decision Tree	93,89%	90,34%

Cấu trúc dữ liệu quyết định lựa chọn mô hình; kết quả chỉ áp dụng cho cấu hình đã khảo sát.

Baseline Covertypes dự đoán tốt nhưng tạo cây rất lớn

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ



93,89%

Accuracy

6,11%

Error rate


90,34%

Macro-F1

Luật: $\text{Elevation} \leq 3044,5 \rightarrow$ nhánh lớp 2. Toàn cây: depth = 41; leaves = 23.956.

Generalization gap xác nhận cây baseline đang overfit

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ



100% train accuracy nhưng chỉ 93,89% test accuracy
⇒ gap 6,11 điểm %.

Vấn đề của baseline xác định đúng chỗ cần cải tiến

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ

Quan sát ở baseline	Phương pháp	Vị trí tác động
Cây tiếp tục phát triển sâu	Pre-pruning	Điều kiện dừng
Nhiều nhánh đóng góp nhỏ	CCP	Topology sau khi fit
Lá ít mẫu dự đoán quá tự tin	Hierarchical Shrinkage	Xác suất tại nút

Chỉ sau khi thấy baseline overfit, nhóm mới đưa các phương pháp cải tiến vào benchmark.

Pre-pruning dừng sớm; CCP cắt cây sau khi fit

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ

Pre-pruning

- Giới hạn max_depth.
- Yêu cầu số mẫu tối thiểu.
- Rủi ro: dừng quá sớm gây underfit.

Cost-Complexity Pruning

$$T_\alpha = \arg \min_{T \subseteq T_0} [R(T) + \alpha |\mathcal{L}(T)|]$$

α lớn tạo cây nhỏ hơn.

Cả hai phương pháp đều thay đổi **topology**.

Hierarchical Shrinkage làm mềm các nút ít mẫu

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ

$$\hat{p}_{HS}(v) = \hat{p}_{HS}(pa(v)) + \frac{n_v}{n_v + \lambda} [\hat{p}(v) - \hat{p}(pa(v))]$$

- n_v lớn: giữ nhiều thông tin của nút con.
- n_v nhỏ hoặc λ lớn: kéo mạnh hơn về nút cha.
- Split, depth và số lá không đổi.

Năm cấu hình tách riêng tác động của từng cải tiến

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ

Cấu hình	Thay đổi	Câu hỏi kiểm tra
E0 Baseline	Không regularization	Điểm xuất phát
E1 Pre-pruning	Dừng sớm	Dừng sớm có đủ không?
E2 CCP	Cắt topology	Cây nhỏ đi bao nhiêu?
E3 HS	Làm mượt prediction	Có giảm phương sai không?
E4 CCP + HS	Kết hợp hai cơ chế	Trade-off có tốt hơn?

α và λ được chọn bằng 3-fold CV chỉ trên tập train.

E3 thắng accuracy; E4 thắng macro-F1


5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ

Cấu hình	Accuracy	Error rate	Macro-F1
E0 Baseline	93,89%	6,11%	90,34%
E1 Pre-pruning	92,97%	7,03%	88,85%
E2 CCP	93,92%	6,08%	90,45%
E3 HS	93,97%	6,03%	90,48%
E4 CCP + HS	93,93%	6,07%	90,53%

Covertypes mất cân bằng nên macro-F1 là tiêu chí ưu tiên.

CCP + HS giảm mạnh độ phức tạp mà không giảm hiệu năng

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ



—31,7%

số lá: 23.956 → 16.361

—17,6%

gap: 6,11 → 5,04 điểm %

+0,19 điểm %
macro-F1

Giá trị chính nằm ở trade-off, không phải accuracy đơn thuần.

Cải tiến chỉ rõ khi dữ liệu và cây đủ lớn

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ

Dataset	Δ Macro-F1	Δ Leaves	Kết luận
Letter Recognition	+0,11 điểm %	0%	Cải thiện rất nhẹ
Handwritten Digits	-0,71 điểm %	-54,9%	Cắt mạnh gây mất điểm
Covertypes	+0,19 điểm %	-31,7%	Trade-off tốt nhất

HS không phải “thuốc tăng điểm” phổ quát; lợi ích phụ thuộc quy mô và độ sâu cây.

Decision Tree phù hợp khi cần tốc độ và khả năng diễn giải

6 | KẾT LUẬN

- **RQ1:** cây đơn mạnh nhất trên Covertypes, nhưng yếu hơn trên Letter và Digits.
- **RQ2:** không có thuật toán thắng mọi dataset; cấu trúc dữ liệu quyết định lựa chọn.
- **RQ3:** CCP + HS phù hợp khi cây sâu, dữ liệu lớn và cần cân bằng hiệu năng với độ phức tạp.

Cây tốt hơn không chỉ chính xác hơn – mà còn gọn hơn, ít overfit hơn và vẫn giải thích được.


Phạm vi: một split chính; backend CPU/GPU khác nhau; chưa chứng minh HS luôn tốt hơn.

Appendix: Kết quả đầy đủ của 3 dataset × 4 model

Dataset	Model	Accuracy	Macro-F1	Error	Tổng time (s)
Letter	Decision Tree	86,77%	86,77%	13,23%	0,084
	Random Forest	95,13%	95,12%	4,87%	3,097
	SVM-RBF	92,31%	92,32%	7,69%	3,707
	KNN	94,08%	94,08%	5,92%	0,005
Digits	Decision Tree	82,50%	82,30%	17,50%	0,021
	Random Forest	96,94%	96,89%	3,06%	0,628
	SVM-RBF	97,22%	97,18%	2,78%	0,718
	KNN	96,39%	96,34%	3,61%	0,003
Covertypes	Decision Tree	93,89%	90,34%	6,11%	7,409
	Random Forest	79,57%	65,86%	20,43%	2,995
	SVM-RBF	79,07%	63,78%	20,93%	125,547
	KNN	92,84%	87,32%	7,16%	5,756

Runtime phản ánh backend và pipeline thực tế; không dùng để suy ra speedup phần cứng thuần túy.

Appendix: Confusion matrix cho thấy lỗi tập trung ở lớp thiểu số



Appendix: Tham số cải tiến được chọn chỉ từ tập train

Dataset	Pre-pruning	CCP	HS
Letter	max_depth=16	$\alpha = 0$	$\lambda = 10$
Digits	max_depth=8 min_samples_leaf	$\alpha = 0,002196$	$\lambda = 10$
Covertime	=5	$\alpha = 3,442 \times 10^{-6}$	$\lambda = 10$

3-fold cross-validation trên train chọn cấu hình; test set chỉ được mở để báo cáo cuối cùng.

5-fold CV độc lập cho baseline Covertime: accuracy $0,9330 \pm 0,0011$; macro-F1 $0,8923 \pm 0,0011$.

Appendix: Hardware, tài liệu và đóng góp nhóm

Hardware/backend. Kaggle GPU x2; cuML ghi nhận Tesla T4 cho RF/SVM/KNN. Decision Tree và HS dùng scikit-learn trên CPU; notebook baseline ghi nhận P100 khả dụng nhưng compute device vẫn là CPU.

Tài liệu chính. Breiman et al. (1984), *Classification and Regression Trees*; Agarwal et al. (2022), *Hierarchical Shrinkage*; UCI Letter Recognition và Covertypes; scikit-learn Digits; RAPIDS cuML.

Đóng góp thành viên.

[HỌ TÊN – MSSV]	[Dữ liệu / baseline / kiểm thử]
[HỌ TÊN – MSSV]	[Benchmark model / Kaggle GPU]
[HỌ TÊN – MSSV]	[Hierarchical Shrinkage / phân tích]
[HỌ TÊN – MSSV]	[Report / slide / tổng hợp kết quả]