

Decision Tree Modeling and Improvement

Từ cây cơ sở đến CCP và Hierarchical Shrinkage

Nhóm thực hiện

[HỌ TÊN – MSSV] [HỌ TÊN – MSSV]

[HỌ TÊN – MSSV] [HỌ TÊN – MSSV]

Introduction to Artificial Intelligence – Lab 2

Trường Đại học Khoa học Tự nhiên – ĐHQG TP.HCM

Sáu chương nổi từ vấn đề đến bằng chứng

- ① **Bối cảnh và động lực** – vì sao cây sâu cần được kiểm soát?
- ② **Các công trình liên quan** – CART, pruning và shrinkage đã giải quyết điều gì?
- ③ **Kiến thức nền tảng** – cây chọn split và suy luận như thế nào?
- ④ **Phương pháp nghiên cứu** – dữ liệu, protocol và cấu hình cải tiến.
- ⑤ **Thực nghiệm và phân tích kết quả** – hiệu năng, overfitting và độ phức tạp.
- ⑥ **Kết luận** – khi nào CCP + HS là lựa chọn hợp lý?

Mạch trình bày đi từ **lý do nghiên cứu** đến **cơ chế**, rồi mới dùng thực nghiệm để trả lời ba câu hỏi nghiên cứu.

Cây dễ giải thích, nhưng cây sâu rất dễ overfit

1 | BỐI CẢNH VÀ ĐỘNG LỰC

Một cây không giới hạn có thể ghi nhớ tập train, tạo hàng chục nghìn lá và dự đoán quá tự tin ở các nhánh ít mẫu.

- ❶ **RQ1 – Phù hợp dữ liệu:** cây đơn hoạt động thế nào trên dữ liệu đa lớp, ảnh và dữ liệu bảng lớn?
- ❷ **RQ2 – So sánh mô hình:** khi nào Decision Tree cạnh tranh được với RF, SVM và KNN?
- ❸ **RQ3 – Cải tiến:** regularization có giảm overfitting mà vẫn giữ hiệu năng và khả năng diễn giải không?

Nguồn: Breiman et al. (1984); mục tiêu nghiên cứu của nhóm.

Nghiên cứu trước giảm phương sai theo ba hướng bổ sung

2 | CÁC CÔNG TRÌNH LIÊN QUAN

Hướng nghiên cứu	Đại diện	Đóng góp	Điểm nhóm kế thừa
Cây phân loại	CART – Breiman et al. (1984)	Split tham lam bằng impurity; luật if-then	Baseline và Cost-Complexity Pruning
Dừng sớm/cắt tỉa	Pre-pruning; CCP	Giới hạn topology để giảm phương sai	So sánh dừng sớm với cắt cây sau khi fit
Làm mượt dự đoán	Hierarchical Shrinkage – Agarwal et al. (2022)	Kéo ước lượng nút con về nút cha	Kiểm tra HS riêng và kết hợp với CCP
Mô hình đối chứng	Random Forest; SVM; KNN	Ensemble, kernel và lân cận cho ranh giới khác nhau	Đặt Decision Tree trong bối cảnh rộng hơn

Khoảng trống nhóm kiểm tra: CCP + HS có tạo cây gọn hơn và giảm gap mà vẫn giữ macro-F1 trên dữ liệu đa lớp quy mô lớn hay không?

CART chọn phép chia làm giảm độ hỗn tạp lớn nhất

3 | KIẾN THỨC NỀN TẢNG

Gini impurity

$$Gini(S) = 1 - \sum_{k=1}^K p_k^2$$

Information gain của split (j, t)

$$\Delta G(j, t) = Gini(S) - \frac{n_L}{n} Gini(S_L) - \frac{n_R}{n} Gini(S_R)$$

$$(j^*, t^*) = \arg \max_{j, t} \Delta G(j, t)$$

Nguồn: CART: Breiman et al. (1984).

Ý nghĩa

- p_k : tỷ lệ lớp k tại nút.
- Gain lớn: hai nút con thuần hơn nút cha.
- Mỗi đường từ gốc đến lá tạo một luật *if-then*.

Hệ quả

- Split tham lam, theo từng trục.
- Cây sâu có phương sai cao.

Huấn luyện lặp đệ quy; suy luận chỉ đi theo một nhánh

3 | KIẾN THỨC NỀN TẢNG

Pseudocode huấn luyện

```
BuildTree(S):  
  if Stop(S): return Leaf( $\hat{p}(y | S)$ )  
   $(j^*, t^*) \leftarrow \arg \max_{j, t} \Delta G(j, t)$   
   $S_L, S_R \leftarrow \text{Split}(S, j^*, t^*)$   
  return Node( $j^*, t^*$ ,  
             BuildTree( $S_L$ ), BuildTree( $S_R$ ))
```

Pseudocode dự đoán

```
Predict(x, v):  
  while v is not leaf:  
    v  $\leftarrow$  left if  $x_j \leq t$   
    else right  
  return  $\arg \max_k \hat{p}_k(v)$ 
```

Nơi regularization can thiệp: điều kiện dừng, topology sau khi fit hoặc xác suất dự đoán tại các nút.

Nguồn: Pseudocode tổng quát hóa từ thuật toán CART.

Ba dataset tạo ra ba điều kiện kiểm thử khác nhau

4 | PHƯƠNG PHÁP NGHIÊN CỨU

Dataset	Mẫu	Features	Lớp	Vai trò
Letter Recognition	18.668	16	26	Stress test đa lớp với đặc trưng hình học
Handwritten Digits	1.797	64	10	Stress test dữ liệu ảnh ít mẫu, nhiều chiều
Covertypes	581.012	54	7	Dataset chính: dữ liệu bảng lớn, mất cân bằng

Covertypes trả lời yêu cầu chính của đề; Letter và Digits kiểm tra độ bền của kết luận trên cấu trúc dữ liệu khác.

Nguồn: UCI Letter Recognition; scikit-learn Digits; UCI Covertypes.

Một protocol chung giúp so sánh công bằng

4 | PHƯƠNG PHÁP NGHIÊN CỨU

Dữ liệu sạch → 80/20 stratified split → train → test cuối cùng

`random_state=42` | scaler chỉ fit trên train cho SVM/KNN |
CV chỉ dùng tập train

Chất lượng dự đoán

- Accuracy và Error rate
- Macro-F1, confusion matrix
- Train-test gap

Hiệu quả và độ phức tạp

- Fit/prediction time
- Độ sâu và số lá
- 3-fold CV chọn tham số

Nguồn: Protocol dùng chung của năm notebook; test set không tham gia chọn siêu tham số.

CCP đổi topology, HS làm mượt xác suất dự đoán

4 | PHƯƠNG PHÁP NGHIÊN CỨU

Pre-pruning. Dừng sớm bằng `max_depth` hoặc `min_samples_leaf`.

Cost-Complexity Pruning.

$$T_{\alpha} = \arg \min_{T \subseteq T_0} [R(T) + \alpha |\mathcal{L}(T)|]$$

Hierarchical Shrinkage.

$$\hat{p}_{HS}(v) = \hat{p}_{HS}(pa(v)) + \frac{n_v}{n_v + \lambda} [\hat{p}(v) - \hat{p}(pa(v))]$$

E0 Baseline E1 Pre-pruning E2 CCP E3 HS **E4 CCP + HS**

α và λ được chọn bằng 3-fold CV chỉ trên tập train.

Nguồn: Breiman et al. (1984); Agarwal et al. (2022); cấu hình benchmark của nhóm.

Không có mô hình tốt nhất trên mọi dataset

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ


Dataset	Mô hình tốt nhất	Accuracy	Macro-F1	Diễn giải
Letter Recognition	Random Forest	95,13%	95,12%	Ensemble giảm phương sai của cây đơn
Handwritten Digits	SVM-RBF	97,22%	97,18%	Kernel phù hợp ranh giới ảnh nhiều chiều
Covertypes	Decision Tree	93,89%	90,34%	Cây khai thác hiệu quả dữ liệu bảng lớn

Cấu trúc dữ liệu quyết định mô hình phù hợp; kết quả chỉ áp dụng cho backend và siêu tham số đã khảo sát.

Nguồn: Notebook so sánh 3 dataset × 4 model; cùng train/test split.

Baseline Covertypes dự đoán tốt nhưng tạo cây rất lớn

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ



93,89%
Accuracy

6,11%
Error rate


90,34%
Macro-F1

Một luật top-level: nếu $Elevation \leq 3044,5$, mẫu đi sang nhánh mà lớp 2 chiếm ưu thế. Cây đầy đủ sâu **41 tầng** với **23.956** lá.

Nguồn: Baseline CART trên Covertypes; hình chỉ hiển thị 3 tầng đầu.

Generalization gap xác nhận cây baseline đang overfit

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ



Covertypes đạt **100% train accuracy** nhưng chỉ **93,89% test accuracy**: gap **6,11 điểm %**.

Nguồn: Train accuracy đo trên mẫu chuẩn đoán cố định; test accuracy đo trên toàn bộ test set.

HS đạt accuracy cao nhất, CCP + HS đạt macro-F1 tốt nhất


5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ

Cấu hình	Accuracy	Error	Macro-F1	Depth	Leaves
E0 Baseline	93,89%	6,11%	90,34%	41	23.956
E1 Pre-pruning	92,97%	7,03%	88,85%	40	16.637
E2 CCP	93,92%	6,08%	90,45%	39	16.361
E3 HS	93,97%	6,03%	90,48%	41	23.956
E4 CCP + HS	93,93%	6,07%	90,53%	39	16.361

Vì Covertypes mất cân bằng, nhóm chọn **E4**: macro-F1 cao nhất, gap thấp hơn và cây nhỏ hơn E3.

CCP + HS cải thiện trade-off, không phải accuracy đơn thuần

5 | THỰC NGHIỆM VÀ PHÂN TÍCH KẾT QUẢ



—31,7%

số lá: 23.956 → 16.361

—17,6%

gap: 6,11 → 5,04 điểm %

+0,19 điểm %

macro-F1: 90,34% → 90,53%

Stress test: Letter +0,11 điểm macro-F1; Digits −0,71; Covertypes +0,19.
Lợi ích rõ nhất khi dữ liệu và cây đủ lớn.

Nguồn: So sánh E0–E4 trên ba dataset; Covertypes có 116.203 mẫu test.

Decision Tree phù hợp nhất khi cần cây gọn và diễn giải được

6 | KẾT LUẬN

RQ1 – Phù hợp dữ liệu: cây đơn mạnh nhất trên Covertypes, nhưng yếu hơn trên Letter và Digits.

RQ2 – So sánh mô hình: không có thuật toán thắng mọi dataset; cấu trúc dữ liệu quyết định lựa chọn.

RQ3 – Cải tiến: CCP + HS phù hợp khi cây sâu, dữ liệu lớn và cần cân bằng hiệu năng với khả năng diễn giải.

Cây tốt hơn không chỉ chính xác hơn – mà còn gọn hơn, ít overfit hơn và vẫn giải thích được.

Phạm vi kết luận: một split chính; backend CPU/GPU khác nhau; chưa chứng minh HS luôn tốt hơn.


Appendix: Kết quả đầy đủ của 3 dataset × 4 model

Dataset	Model	Accuracy	Macro-F1	Error	Tổng time (s)
Letter	Decision Tree	86,77%	86,77%	13,23%	0,084
	Random Forest	95,13%	95,12%	4,87%	3,097
	SVM-RBF	92,31%	92,32%	7,69%	3,707
	KNN	94,08%	94,08%	5,92%	0,005
Digits	Decision Tree	82,50%	82,30%	17,50%	0,021
	Random Forest	96,94%	96,89%	3,06%	0,628
	SVM-RBF	97,22%	97,18%	2,78%	0,718
	KNN	96,39%	96,34%	3,61%	0,003
Covertypes	Decision Tree	93,89%	90,34%	6,11%	7,409
	Random Forest	79,57%	65,86%	20,43%	2,995
	SVM-RBF	79,07%	63,78%	20,93%	125,547
	KNN	92,84%	87,32%	7,16%	5,756

Runtime phản ánh backend và pipeline thực tế; không dùng để suy ra speedup phần cứng thuần túy.

Nguồn: `gpu_three_dataset_four_model_comparison_summary.csv`.

Appendix: Confusion matrix cho thấy lỗi tập trung ở lớp thiểu số



Nguồn: Decision Tree baseline trên tập test Covertypes.

Appendix: Tham số cải tiến được chọn chỉ từ tập train

Dataset	Pre-pruning	CCP	HS
Letter	max_depth=16	$\alpha = 0$	$\lambda = 10$
Digits	max_depth=8 min_samples_leaf	$\alpha = 0,002196$	$\lambda = 10$
Covertypes	=5	$\alpha = 3,442 \times 10^{-6}$	$\lambda = 10$

3-fold cross-validation trên train chọn cấu hình; test set chỉ được mở để báo cáo cuối cùng.

5-fold CV độc lập cho baseline Covertypes: accuracy $0,9330 \pm 0,0011$; macro-F1 $0,8923 \pm 0,0011$.

Nguồn: HS CV selection; Covertypes scalability cross-validation.

Appendix: Hardware, tài liệu và đóng góp nhóm

Hardware/backend. Kaggle GPU x2; cuML ghi nhận Tesla T4 cho RF/SVM/KNN. Decision Tree và HS dùng scikit-learn trên CPU; notebook baseline ghi nhận P100 khả dụng nhưng compute device vẫn là CPU.

Tài liệu chính. Breiman et al. (1984), *Classification and Regression Trees*; Agarwal et al. (2022), *Hierarchical Shrinkage*; UCI Letter Recognition và Covertypes; scikit-learn Digits; RAPIDS cuML.

Đóng góp thành viên.

[HỌ TÊN – MSSV]	[Dữ liệu / baseline / kiểm thử]
[HỌ TÊN – MSSV]	[Benchmark model / Kaggle GPU]
[HỌ TÊN – MSSV]	[Hierarchical Shrinkage / phân tích]
[HỌ TÊN – MSSV]	[Report / slide / tổng hợp kết quả]

Nguồn: Metadata notebook; tài liệu tham khảo trong report.